

الجمهورية العربية السورية
المعهد العالي للعلوم التطبيقية والتكنولوجيا
قسم النظم المعلوماتية
العام الدراسي 2024/2025

مشروع تخرج

أعد للنجاح في السنة الخامسة

كشف الأحداث ومراقبتها في وسائل التواصل الاجتماعي اعتماداً على تقنيات التعلم العميق

تقديم

حسن بهجت خضور

إشراف

د. رياض سنبل

11/8/2025

الخلاصة

يهدف هذا المشروع إلى

Abstract

Translate your abstract here.

المحتويات

1	الفصل الأول
1	التعريف بالمشروع
2	1.1- مقدمة
2	2.1- الهدف من المشروع
2	3.1- نطاق المشروع
3	4.1- المتطلبات الوظيفية
4	5.1- المتطلبات غير الوظيفية
5	الفصل الثاني
5	الدراسة النظرية
6	3.1- العنقدة CLUSTERING
6	1.3.1 العنقدة القائمة على الكثافة Density Based Clustering
6	1.3.1- العنقدة Online Clustering
7	3.1- شبكات البيان العصبونية GRAPH NEURAL NETWORK
7	3.1- التعلم المقارن CONTRASTIVE LEARNING
8	3.1.1- التعلم المقارن على البيان Graph Contrastive Learning
9	3.1- تقنيات تضمين الكلمات WORD EMBEDDING
9	1.1.1 المحولات Transformers
9	1.1.1 نموذج Bert (Bidirectional Encode Representation from Transformers)
10	2.1.2 Word2Vec
10	2.1.2 FastText
10	3.1- LDA (LATENT DIRICHLET ALLOCATION)
11	3.1- شبكات المعلومات غير المتجانسة (HIN)
11	2.1- التعرف على الكيانات المسماة NAMED ENTITIES RECOGNITION
12	3.1- معمارية الخدمات المصغرة MICRO SERVICES ARCHITECTURE
12	3.1- ممارسة التكامل المستمر والتسليم المستمر CI/CD

12	3.1- البنية المعمارية النظيفة
14	الفصل الثالث
14	الدراسة المرجعية
15	1.1- مقدمة
15	1.1- مسألة كشف الأحداث في دفق بيانات
16	1.1.1 الإطار العام للمسألة
18	1.1.1 المراحل الرئيسية لسير العمل في نظام لكشف الأحداث
19	1.1.1 تعريف المسألة Problem Definition
19	1.1.1 طرق معالجة المسألة
20	1.1.1 المنهجيات والمقاربات لمعالجة المسألة
22	1.1.1 النموذج HCRC
24	1.1.1 معايير التقييم وقياس الأداء
24	أ. Normalized Mutual Information (NMI)
24	ب. Adjusted Mutual Information (AMI)
24	ت. B-Cubed
25	1.1.1 مجموعات البيانات المتاحة
27	3.1- مسألة الاستدلال على الموقع الجغرافي من النص
27	1.1.1 الإطار العام للمسألة
28	1.1.1 المنهجيات والمقاربات المتبعة للتعرف على الموقع
29	1.1.1 استخدام نماذج اللغة الكبيرة لاستدلال الموقع المذكور
30	1.1.1 تعريف المسألة Problem Definition
31	1.1.1 مجموعات البيانات المتاحة
31	1.1.1 معايير التقييم وقياس الأداء
32	4.1- أنظمة مشابهة
32	1.4.1 Liveuamap.com Live Universal Awareness Map
33	3.4.1 Globalincidentmap.com Global Incidents Map
34	2.4.1 Emergency and Disaster Information Service (EDIS) rsoe-edis.org
35	3.1- خلاصة الدراسة المرجعية
36	الفصل الرابع

36	الدراسة التحليلية
37	1.1- مقدمة
37	3.1- مخطط حالات الاستخدام
39	4.1- السرد النصي لحالات الاستخدام
41	4.1- مخطط المكونات
42	4.1- العلاقات بين الفاعلين
43	الفصل الخامس
43	المنهجية المقترحة
44	1.1- مقدمة
45	وحدة البحث واستخراج دفع الرسائل
45	وحدة فلترة دفع الرسائل
46	وحدة كشف الأحداث
47	وحدة تلخيص الحدث
47	وحدة الاستدلال على الموقع
48	الفصل السادس
48	تصميم النظام
49	1.1- مقدمة
50	3.1- مخطط خدمات النظام التصميمي
51	2.1- تصميم خدمات النظام
56	الفصل السابع
56	الأدوات المستخدمة
57	1.1- DOCKER
57	2.1- ASP.NET WEB API
58	الفصل الثامن
58	التجارب ومقارنة النماذج
59	1.1- مجموعة البيانات
65	2.1- تجارب تصنيف التغريدات
68	التجربة الثانية: تنزيل شعاع الكيانات المسماة

69	التجربة الثالثة: تمثيل الكيانات المسماة فقط.....
70	التجربة الرابعة: استبدال الكيانات المسماة بكلمات بدل Placeholders
71	2.1- تجارب كشف الأحداث (نمذجة المواضيع).....
71	1.1.1 تقييم النماذج بنمط عدم الاتصال Offline Evaluation
76	التجربة الثانية: خوارزمية العنقدة الهرمية HDBSCAN
80	التجربة الثالثة: إضافة شعاع الكيانات المسماة
83	التجربة الرابعة: نموذج HCRC المرجعي
86	1.1.1 تقييم النماذج بنمط الحي Online Evaluation
86	التجربة الأولى
91	التجربة الثانية: إضافة شعاع الكيانات المسماة
93	التجربة الثالثة: إضافة شعاع الكيانات المسماة بشكل منفصل
96	التجربة الرابعة: النموذج المرجعي HCRC
98	الفصل التاسع
98	تنجيز النظام
99	1.1- مقدمة
100	2.1- تنجيز الخدمات
100	خدمة سحب البيانات
102	خدمة إدارة عمليات السحب
102	خدمة كشف الأحداث
102	خدمة الاستدلال على الموقع
103	خدمة إدارة الأحداث
104	خدمة البوابة
104	خدمة واجهة المستخدم
104	خدمة الهوية
105	خدمة استخراج الكيانات المسماة
105	3.1- مخطط النظام
105	3.1- نشر الخدمات
106	الفصل العاشر
106	تحليل ومناقشة النتائج
107	1.1- مقدمة
107	2.1- معايير التقييم
108	الفصل الحادي عشر
108	اختبارات النظام
109	1.1- مقدمة

109	2.1- اختبار خدمات النظام
109	اختبار خدمة سحب البيانات
110	اختبار خدمة سحب البيانات
110	3.1- اختبارات الأداء
118	مقدمة
118	عدد الأحداث اليومي
118	كمية البيانات الواجب سحبها
119	معدل دفع التغريدات
119	عدد المستخدمين المتوقع
121	دليل تعليمات تصنيف التغريدات
121	الغرض
121	معايير التصنيف
121	أمثلة على تصنيف التغريدات

مقدمة عامة

أصبحت وسائل التواصل الاجتماعي اليوم أحد المصادر الرئيسية لنشر المعلومات حول الأحداث اليومية، حيث يقوم المستخدمون بمشاركة الأخبار العاجلة، الكوارث الطبيعية، الجرائم، الحوادث والأحداث الاجتماعية بمجرد وقوعها. ومع النمو السريع في حجم المحتوى المنشور على هذه المنصات، أصبحت هناك حاجة ملحة إلى أنظمة ذكية قادرة على استخراج وتحليل هذه البيانات بشكل آلي لتوفير معلومات دقيقة وتقارير عن الأحداث الجارية.

يعتمد كشف الأحداث على تقنيات معالجة اللغة الطبيعية (NLP) والتعلم العميق لفهم وتحليل المحتوى النصي المنشور على وسائل التواصل الاجتماعي، واستخراج المعلومات ذات الصلة مثل نوع الحدث، وموقعه الجغرافي. كما يتضمن ذلك استخدام تقنيات التعرف على الكيانات المسماة (NER) لاستخلاص الأسماء، الأماكن، والمنظمات المذكورة في النصوص، بالإضافة إلى تقنيات التحليل الجغرافي لتحديد مواقع الأحداث حتى في حال عدم توفر إحداثيات جغرافية مباشرة. تعد هذه العملية ذات أهمية كبيرة في العديد من المجالات، مثل:

- الاستجابة للكوارث والطوارئ: تمكين فرق الإغاثة والجهات الحكومية من الحصول على معلومات دقيقة وفورية حول الكوارث الطبيعية مثل الزلازل والفيضانات والحرائق.
- تحليل الجرائم والأمن العام: مساعدة الأجهزة الأمنية في تتبع الجرائم وحوادث العنف والسرقات فور الإبلاغ عنها عبر وسائل التواصل الاجتماعي.
- رصد الأحداث الاجتماعية والسياسية: تمكين الصحفيين والباحثين من متابعة التغيرات المجتمعية والتطورات السياسية في الزمن الحقيقي.
- إدارة المدن الذكية: تحسين إدارة البنية التحتية والخدمات العامة من خلال مراقبة شكاوى المواطنين وتفاعلهم مع الأحداث المحلية.

يهدف هذا المشروع إلى تقديم نظام متكامل قادر على تحليل تدفقات البيانات الاجتماعية، استخراج المعلومات منها، وعرضها بشكل مرئي يسهل فهمها، مما يساهم في تعزيز الوعي بالأحداث الجارية واتخاذ قرارات مبنية على بيانات دقيقة مرئية.

الفصل الأول

التعريف بالمشروع

نبيّن في هذا الفصل هدف المشروع ونطاقه كما نورد المتطلبات الوظيفية وغير الوظيفية.

1.1- مقدمة

في وقتنا الحال، أصبحت وسائل التواصل الاجتماعي مصدرنا رئيسياً للأخبار والمعلومات، فعدت تقدم لنا دفقاً من البيانات من المهم معالجته واستخلاص المعلومات المهمة منه وعرضها بشكل مرئي يساعد الجهات والمنظمات المعنية على اتخاذ القرارات.

2.1- الهدف من المشروع

يندرج عملنا في هذا المشروع ضمن سياقين اثنين: (1) الأول نتطرق فيه للمسألة من منظور الذكاء الصناعي، حيث نحاول توظيف تقنياته وأدواته في الوصول إلى مقارنة لحل مسألتين مطروحتين هما أ. كشف الأحداث من دفق بيانات، ب. الاستدلال على الموقع الجغرافي من رسالة نصية، (2) والثاني نتطرق فيه إلى بناء تطبيق برمجي يستفيد من المقارنة المقترحة في تنفيذ التطبيق عملياً مع مراعاة الأسس والمبادئ المتبعة في هندسة البرمجيات وصولاً إلى تطبيق قابل للتوسع وسهل الصيانة.

3.1- نطاق المشروع

نطاق هذا المشروع يقتصر على تطوير نظام لاكتشاف الأحداث المحلية باللغة العربية باستخدام بيانات وسائل التواصل الاجتماعي وتحليلها باستخدام تقنيات الذكاء الاصطناعي والتعلم العميق. ويركز المشروع على تطبيق تقنيات التعلم العميق لتحليل النصوص المستخلصة، مع الهدف الرئيسي لكشف الأحداث المحلية مثل الحوادث، الجرائم.

مكونات المشروع:

1. جمع البيانات: سيتم جمع البيانات من وسائل التواصل الاجتماعي، مثل تويتر، تليغرام، باستخدام واجهات برمجة التطبيقات (APIs) المتاحة لهذه الشبكات وباستخدام الزواحف.
2. تحليل النصوص: استخدام تقنيات التعلم العميق، لتحليل النصوص ونمذجتها. بالإضافة إلى استخراج الكيانات الأساسية مثل الأماكن والأشخاص لهذه الأحداث باستخدام تقنيات التعرف على الكيانات المسماة (NER).
3. التحليل الجغرافي: التعرف على المواقع الجغرافية من البيانات المستخلصة، سواء عبر البيانات الجغرافية المرفقة (الموسومة جغرافياً) أو من خلال الاستدلال على المواقع. وتطوير آلية لتحويل النصوص الجغرافية إلى إحداثيات جغرافية عبر مرمز جغرافي (Geocoder).
4. النظام التفاعلي: تطوير تطبيق ويب تفاعلي لعرض الأحداث المكتشفة على خرائط تفاعلية في الزمن الحقيقي، مما يسمح للمستخدمين بمراقبة الأحداث وتقييمها على الخريطة. وتقديم تقارير وبيانات إحصائية حول الأحداث المكتشفة.

4.1- المتطلبات الوظيفية

نبين هنا المتطلبات الوظيفية التي يجب أن يحققها النظام.

يجب على النظام أن يسمح للمستخدمين بما يلي:

1. استعراض الأحداث حسب المنطقة الجغرافية
 2. استعراض الأحداث التي قد مرت (حسب التاريخ)
 3. تحديد منطقة جغرافية، لتلقي إشعارات بالأحداث التي تقع بها
 4. استخراج مخططات ورسوم توضيحية حول الأحداث وتسلسلها الزمني.
- يجب على النظام أن يسمح للمراقب بما يلي:

1. إدارة الأحداث، أي حذفها، تعديل موقعها، أهميتها، وإضافة معلومات عنها.
 2. إدارة التصنيفات، أي إضافة- حذف- تعديل تصنيف.
- يجب على النظام ان يسمح لمدير النظام بما يلي:
1. إدارة مصادر البيانات، أي تعديل مصادر سحب البيانات، إضافة مصادر جديدة، حذف مصادر قديمة.
- يجب على النظام أن يقوم بما يلي:

1. جدولة الأحداث بشكل يومي، بحيث يعرض على المستخدم الأحداث اليومية على الخريطة.
2. إرسال إشعارات للمستخدمين عند وقوع أحداث ضمن مناطق اهتمامهم.
3. استخراج (تجريف Scrape) البيانات من وسائل التواصل الاجتماعي مثل تويتر وتيليغرام والمنصات الإخبارية.
4. التخاطب مع APIs وسائل التواصل الاجتماعي وجمع البيانات منها.
5. تمرير البيانات في بيئة دفقية streaming ضمن النظام.

5.1- المتطلبات غير الوظيفية

نورد هنا المتطلبات غير الوظيفية أي القيود على النظام لكي يتم قبوله. حيث قمنا بتقسيمها إلى عدة محاور وهي متطلبات الأمان ومتطلبات الأداء ومتطلبات خاصة ومتطلبات التشغيل.

أ. متطلبات الأمان

1. يجب أن يكون الدخول إلى النظام آمناً، أي يجب أن يسمح فقط للمستخدمين المسجلين بالدخول إليه.

2. أن يسمح للمستخدمين القيام بالعمليات وفقاً لما هم مخولين به من صلاحيات فقط.

ب. متطلبات الأداء

1. يجب أن يستجيب النظام لطلبات المستخدم في غضون زمن محدد لا يتجاوز 2 ثانية لمعظم العمليات.

2. أن يكون النظام قادراً على معالجة دفق البيانات وفق السعة الموضحة بالدراسة الكمية (100 رسالة في الدقيقة)، وفقاً للدراسة الكمية (اضغط هنا).

3. أن يكون النظام قادراً على استخراج دفق بيانات (data streams) بسعة لا تقل عن 1000 رسالة في الساعة.

ت. متطلبات خاصة

1.

ث. متطلبات التشغيل

1. أن تعمل الخدمات ضمن حاويات مستقلة لكل خدمة.

الفصل الثاني

الدراسة النظرية

يوضح هذا الفصل بعض المفاهيم المستخدمة في هذا العمل.

3.1- العنقدة Clustering

العنقدة، وهي عملية من تقنيات تعلم الآلة غير الخاضعة للإشراف unsupervised، حيث تقوم على تجزئة مجموعة من البيانات (العناصر) إلى مجموعات جزئية --أي عناقيد-- بحيث تكون العناصر الموجودة في العنقود الواحد متشابهة مع بعضها البعض، وتختلف عن العناصر الموجودة في المجموعات الأخرى. وتصنف طرق العنقدة بشكل عام في أربع مجموعات: (1) طرائق التجزئة Partitioning Based، حيث يتم تحديد عدد العناقيد مسبقاً، أو (2) القائمة على الشبكة Grid Based، حيث يتم تقسيم فضاء العناصر إلى عدد محدد مسبقاً من الخلايا، أو (3) هرمية Hierarchical، حيث يتم تنظيم البيانات في مستويات متعددة، أو (4) قائمة على الكثافة Density Based، حيث يتم أخذ الكثافة بالاعتبار (Igartua et al., 2020).

1.3.1 العنقدة القائمة على الكثافة Density Based Clustering

تنظم خوارزميات العنقدة القائمة على الكثافة البيانات في المناطق (العناقيد) حيث تكون العناصر كثيفة والتي تفصل عن بعضها بمناطق ذات كثافة عناصر منخفضة، والتي تعتبر ضجيج. وهذه الخوارزميات قادرة على (1) اكتشاف مجموعات من الأشكال الاعتبائية arbitrary، (2) التعامل مع المناطق المفرغة sparse (التي تعتبر مناطق ضجيج) و (3) العمل دون معرفة عدد العناقيد مسبقاً (Igartua et al., 2020). ومن بين المقترحات المختلفة في الأدبيات يوجد DBSCAN (التجميع المكاني القائم على الكثافة للتطبيقات ذات الضجيج Density-Based Spatial Clustering of Applications with Noise). DBSCAN هي خوارزمية شائعة للعنقدة القائمة على الكثافة، تجمع النقاط المتراسة مع بعضها البعض، مع تمييز النقاط في المناطق منخفضة الكثافة كقيم شاذة. حيث وبخلاف K-means، لا تتطلب DBSCAN تحديد عدد العناقيد مسبقاً، ويمكنها تحديد العناقيد ذات الأشكال المختلفة. يعتمد أدائها على معاملين: ϵ (نصف قطر الجوار) و MinPts (الحد الأدنى لعدد النقاط اللازمة لتكوين منطقة كثيفة). تتميز DBSCAN بفعالية خاصة في قواعد البيانات المكانية والتحليل الجغرافي المكاني (Ester et al., 1996).


1.3.1- العنقدة Online Clustering

تشير العنقدة الحية، والمعروفة أيضاً بالعنقدة التزايدية (Incremental Clustering)، أو العنقدة التدفقية (Streaming Clustering)، إلى تقنيات العنقدة التي تحدّث العناقيد ديناميكياً مع وصول بيانات جديدة، دون الحاجة إلى إعادة معالجة مجموعة البيانات بأكملها. ويكتسب هذا أهمية خاصة في الحالات التي تتضمن بيانات واسعة النطاق أو آنية، مثل شبكات الاستشعار، والتوصيات عبر الإنترنت، وتدفقات وسائل التواصل الاجتماعي. تهدف خوارزميات مثل خوارزمية K-means

التزايدية النسخ الحية من DBSCAN إلى التكيف بكفاءة مع انحراف المفاهيم وضمان قابلية التوسع مع ذاكرة محدودة (Aggarwal et al., 2003).


3.1- شبكات البيان العصبونية Graph Neural Network

تعد شبكات البيان العصبونية GNNs، نوعاً من الشبكات العصبونية المصمم للتعامل مع بيانات مهيكلة على شكل بيان Graph، الفكرة الرئيسية هنا هي تمرير الرسائل Message Passing، حيث كل تقوم كل عقدة في البيان بتجميع المعلومات من العقدة المجاورة، وتستخدم تلك المعلومات لتحديث تمثيلها، ومن خلال تكديس عدد من طبقات GNN، تستطيع العقدة التعلم من عقد مجاورة أوسع، مما يسمح للنموذج بتعلم والتقاط معلومات وعلاقات معقدة من الهيكلية الكلية للبيان.



3.1- التعلم المقارن Contrastive Learning


يعد التعلم المقارن نموذجاً قوياً ضمن مجال التعلم المشرف عليه ذاتياً Self-Supervised Learning Paradigm، حيث يتم تدريب النموذج على التمييز بين العينات المتشابهة، عن العينات غير المتشابهة (Positive Samples, Negative Samples)، الفكرة الأساسية هنا تكمن في سحب التضمنين الضمني للثنائيات الموجبة Positive Pair، بالقرب من بعضهم البعض، وبأن معاً إبقاؤهم بعيداً عن العينات السالبة. هذه الطريقة تجبر النموذج على استخراج سمات تمييزية من البيانات من دون الحاجة إلى بيانات منمطة. أي باختصار يحاول التعليم المقارن تعظيم الاتفاق بين التمثيلات الضمنية للعينات المتشابهة، تحت مجموعة بيانات معززة بطريقة مدروسة.



الشكل 1: مثال توضيحي على التعلم المقارن.

3.1.1- التعلم المقارن على البيان Graph Contrastive Learning

هو حالة خاصة من التعلم المقارن، حيث يكون على بيان، وهو غالباً ما يتكون من مكون لإنشاء وجهات نظر مختلفة للبيان، من أجل تشكيل عينات سالبة وموجبة، بالإضافة إلى هدف مقارنة لتمييز العينات الموجبة عن السالبة. ويتم تعزيز البيان (توليد وجهات نظر موجبة) من خلال إحدى الطرق التالية، إضافة وصلات بين العقد، حذف وصلات بين العقد، حذف عقد، تعمية عقد ما، إضافة خصائص للعقد.



3.1- تقنيات تضمين الكلمات Word Embedding

يعتبر تضمين الكلمات تقنية هامة في معالجة اللغات الطبيعية وتعلم الآلة، حيث تهدف هذه التقنية إلى تمثيل الكلمات بصورة رقمية (شعاعية) قابلة للمعالجة من قبل النماذج الحاسوبية. حيث يتم تحويل الكلمات إلى أشعة متعددة الأبعاد تعكس المعاني والعلاقات الدلالية والنحوية فيما بينها. حيث تعتمد تقنيات تضمين الكلام على فكرة أساسية وهي أن الكلمات ذات المعاني المتشابهة يكون لها تمثيلات شعاعية متقاربة في فضاء التضمين، وبالمثل الكلمات ذات المعاني المختلفة تكون بعيدة في فضاء التضمين. ويتم عملية تضمين الكلمات باستخدام نماذج التعلم العميق، ويتم تدريب هذه النماذج على مجموعة كبيرة من المدونات، وتنقسم نماذج التضمين إلى نوعين، ثابتة _ تعطي شعاع تضمين للكلمة بغض النظر عن سياقها، سياقية _ تعطي شعاع تضمين حسب سياق الجملة حيث يتغير شعاع التضمين للكلمة حسب سياقها.

1.1.1 المحولات Transformers


تُعد تقنية المحولات (Transformers) من الابتكارات الرائدة في مجال معالجة اللغة الطبيعية (NLP)، وقد تم تقديمها لأول مرة في عام 2017. وتُعتبر هذه التقنية بمثابة ثورة في هذا المجال نظرًا لقدرتها الفائقة على فهم النصوص وتوليدها بشكل فعال ودقيق. تعتمد المحولات على نموذج تعلم عميق يتألف من عدة طبقات من الشبكات العصبية، ويتم تدريبه على مجموعات ضخمة من البيانات النصية بهدف تمكينه من فهم البنية اللغوية وتوليد نصوص ذات معنى. ما يميز هذه التقنية هو قدرتها على التعامل مع السياقات الطويلة في النصوص، حيث تستطيع فهم العلاقات بين الكلمات، والجمل، والفقرات بشكل متكامل. كما تعتمد المحولات بشكل أساسي على آلية الانتباه (Attention Mechanism)، التي تُتيح للنموذج تركيز اهتمامه على الأجزاء الأهم في النص أثناء المعالجة (Vaswani et al., 2023).

1.1.1 نموذج Bert (Bidirectional Encode Representation from Transformers)

يعتبر واحد من أحدث نماذج التضمين الدلالي، ويعتمد في بنيته على المحولات (Transformers)، ما يميز هذا النموذج عن غيره من النماذج التي سبقته هو قدرته على توليد أشعة تضمين تأخذ السياق بعين الاعتبار، أي تضمين الكلمة يختلف حسب سياقها. حيث يتم تدريب هذا النموذج على مهمتين هما، مهمة تعبئة الفراغات (MLM (Masked Language Model بحيث يتم استبدال مجموعة من كلمات الجملة برمز خاص Mask ويكون هدف النموذج هو التنبؤ بهذه الكلمات، والثاني هو التنبؤ بالجملة التالية (NSP (Next Sentence Prediction والدخل هنا هو جملتين والخرج هو 0 أو 1 إذا كانت الجملة الثانية هي الجملة التالية أم لا (Devlin et al., 2019).

Word2Vec 2.1.2

يعد هذا النموذج الأول من نوعه في هذا المجال، حيث تم إصداره من Google عام 2013، وهو نموذج تضمين ثابت، يمكنه التعلم على مدونات ضخمة غير منمطة، عن طريق إحدى مهمتين، الأولى Continuous Back of Words، حيث يتم تدريب النموذج على التنبؤ بالكلمة بناءً على الكلمات المحيطة بها، والأخرى هي Skip Gram Model، بحيث يتم التدريب على التنبؤ بالكلمات المحيطة بالكلمة الحالية، والشكل أدناه يوضح ذلك (Mikolov et al., 2013).



الشكل 2: نموذج Skip Gram و CBOW.

FastText 2.1.2


هو نموذج تضمين ثابت مشابه لـ Word2Vec، تم إصداره من قبل Facebook عام 2017، وما يتميز به هذا النموذج هو قدرته على فهم الكلمات حتى لو كان بها أخطاء إملائية أو نحوية، بالإضافة إلى فهم اللهجات، وذلك لأنه يأخذ الحروف في عين الاعتبار عند تعلم التمثيل character n-grams. وكما في Word2Vec يتم تدريب النموذج بأحد الطريقتين Skip Gram، CBOW (Bojanowski et al., 2017).

3.1 - LDA (Latent Dirichlet Allocation)

LDA، هو خوارزمية شائعة في معالجة اللغات الطبيعية NLP من أجل نمذجة المواضيع، وهو عبارة عن نموذج إحصائي يساعد على اكتشاف المواضيع ضمن مجموعة من المستندات، بحيث كل مستند هو عبارة عن مجموعة من المواضيع، وكل موضوع هو عبارة عن مجموعة من الكلمات. وبشكل أساسي يهدف LDA إلى الكشف عن الهياكل الموضوعية الضمنية ضمن مدونة نصية.

3.1- شبكات المعلومات غير المتجانسة (HIN)

شبكات المعلومات غير المتجانسة (HIN) Heterogeneous Information Networks، وهي حالة خاصة من البيان Graph، حيث يحتوي هذا على أكثر من نوع من العقد والوصلات. أي كما يلي، $G = (V, E, \mathcal{N}, T)$ حيث V و E هما مجموعات العقد والوصلات و $\mathcal{N}$ و T هما مجموعات أنواع العقد والوصلات، حيث لكل عقدة نوع من $\mathcal{N}$ و لكل وصلة نوع من T ، فعلى سبيل المثال في حالتنا، تكون الرسالة m وهي عقدة (من نمط رسالة) مرتبطة مع عقد الأماكن المذكورة في نصها (وهذه العقد تكون من نوع أماكن)، وتكون أيضاً هذه الرسالة مرتبطة مع عقد الـ Hashtags المذكورة فيها (وهي عقد من نوع Hashtag)، وبذلك وبالمرور على كل الرسائل الواردة في هذه الشريحة المنية، نكون قد شكلنا هذه الشبكة. ويوضح الشكل أدناه مثالاً عن ذلك.



رسم توضيحي 1: مثال على شبكة معلومات غير متجانسة.

2.1- التعرف على الكيانات المسماة Named Entities Recognition

يعرف الكيان المسمى Named Entity بأنه كائن واقعي يملك تعريفاً مناسباً، ويمكن الإشارة له باسمه المناسب. حيث يمكن أن تكون الكيانات المسماة مكاناً أو شخصاً أو منظمة أو عنصراً أو كياناً جغرافياً أو وقتاً. وكمثال عن الكيانات المسماة فـ "المعهد العالي" هو كيان مسمى من نوع مؤسسة. وتتم عملية التعرف على الكيانات المسماة باستخدام أدوات وتقنيات معالجة اللغات الطبيعية، حيث تقوم بتصنيف مفردات النص المدخل إلى فئات محددة مسبقاً تمثل الكيانات المسماة.

3.1- معمارية الخدمات المصغرة Micro services Architecture


تمثل الخدمات المصغرة أسلوباً معمارياً حديثاً يحل التطبيقات التقليدية ذات الكتلة الواحدة Monolithic Application، إلى مجموعة من الخدمات المصغرة الموزعة القابلة للنشر بشكل مستقل عن بعضها البعض. يعزز هذا النهج المرونة في بناء التطبيقات وقابلية التوسع ويزيد من إنتاجية المطورين، من خلال السماح للفرق بالعمل بشكل مستقل على خدمات مختلفة. وتتميز الخدمات المصغرة بتماسكها الداخلي العالي (High Cohesion) وارتباطها الخفيف (Low Coupling) مما يسهل تطوير التطبيقات المعقدة.

3.1- ممارسة التكامل المستمر والتسليم المستمر CI/CD

يُعد التكامل المستمر (CI) والنشر المستمر (CD) من الممارسات الأساسية في تطوير البرمجيات الحديثة، لاسيّما ضمن بيئات وأطر عمل DevOps. تهدف تقنيات CI/CD إلى أتمتة عمليات اختبار البرمجيات ونشرها، مما يتيح للفرق التقنية إمكانية تقديم التحديثات بسرعة وكفاءة بعد حدوث أي تعديل في الشيفرة المصدرية (Source Code). وتساهم هذه الممارسات في تقليل الأخطاء البشرية، وتحسين جودة المنتج، وتسريع دورة التطوير والنشر.

3.1- البنية المعمارية النظيفة

تُعد البنية النظيفة (Clean Architecture) فلسفة تصميم برمجي تهدف إلى بناء أنظمة قابلة للتوسع، سهلة الصيانة، وقابلة للاختبار. تستند هذه البنية إلى مبدأ فصل مكونات النظام إلى طبقات مستقلة، بحيث يكون لكل مكون مسؤولية واضحة ومعزولة عن تفاصيل التنفيذ، مثل قاعدة البيانات أو واجهة المستخدم. تُركّز البنية النظيفة على عزل منطق الأعمال (Business Logic) عن الأطر الخارجية (مثل قواعد البيانات، الشبكة، أو واجهات العرض)، مما يتيح تطوير كل مكون أو تغييره دون التأثير على باقي النظام. يؤدي هذا النهج إلى تقليل التعقيد العام للنظام، ويعزز من مرونته وقدرته على التكيف مع التغيرات المستقبلية [1]. ومن أبرز خصائص البنية النظيفة: (1) أن منطق التطبيق مستقل عن إطار العمل المستخدم، (2) أن آلية تخزين البيانات يمكن تغييرها دون المساس بمنطق الأعمال، و(3) أن النظام يكون أكثر قابلية للاختبار والتطوير المستمر.



الفصل الثالث

الدراسة المرجعية

نبيّن في هذا الفصل الأبحاث والأعمال والمنهجيات المشابهة لهذا العمل.

1.1- مقدمة

تعد مسألة اكتشاف الأحداث وتصنيفها من وسائل التواصل الاجتماعي من التحديات البحثية الهامة التي تجمع بين عدة مجالات في الذكاء الاصطناعي، مثل معالجة اللغة الطبيعية (NLP)، واستخراج المعلومات، وتحليل البيانات الضخمة. تعتمد هذه المسألة على تحليل دفع من النصوص المنشورة لاستخلاص الأحداث المهمة وتصنيفها وفقاً لنوعها، مثل الجرائم، والحوادث المرورية.

إضافةً إلى ذلك، يُعتبر استنباط الموقع الجغرافي للأحداث من النصوص غير المهيكلة تحدياً إضافياً، حيث يتطلب تقنيات متقدمة لاستخلاص المعلومات الجغرافية وربطها بإحداثيات دقيقة. يهدف هذا القسم إلى تعريف المسألة ومراجعة الأعمال البحثية السابقة في مجال كشف الأحداث وتصنيفها، استخراج الموقع الجغرافي من النصوص، بالإضافة إلى استعراض الأنظمة المشابهة ومجموعات البيانات المتاحة لدعم هذه المهام.

1.1- مسألة كشف الأحداث في دفع بيانات

إنَّ التطور السريع لمنصات وسائل التواصل الاجتماعي أدى إلى تضخم في البيانات المنشورة من قبل المستخدمين على الإنترنت. حيث مكنت هذه البيانات الضخمة من دراسة العديد من المشكلات البحثية، وواحد من مواضيعها المهمة هو كشف الأحداث (Q. Li et al., 2022).

وبالانتقال إلى تعريف الحدث، فإن التعريف يختلف قليلاً في الدراسات السابقة حيث يعرفه McMin وآخرون بشكل عام على أنه "شيء مهم يحدث في زمان ومكان محددين"، بينما يعرفه Xie وآخرون على أنه "حدث في العالم الحقيقي، وقع في زمان ومكان معينين، شارك به أو اثر بمجموعة من الأشخاص فحفزهم على التكلم عنه". وبشكل عام يمكننا أن نصفه بما يسمى الـ 4Ws (What, Where, Who & When). بينما يعرف Chao وآخرون الحدث المحلي كما يلي "الحدث المحلي (على سبيل المثال، الاحتجاج، الجريمة، الكوارث الطبيعية) هو نشاط غير عادي ينفجر في منطقة محلية وخلال مدة محددة ويشترك به (أو يتفاعل معه) عدد كبير من المشاركين".

ولطالما تم تناول كشف الأحداث من الوسائط التقليدية في سياق كشف المواضيع وتتبعها Topic Detection and Tracking (TDT)، ومع ذلك فإنَّ اكتشاف الأحداث من وسائل التواصل الاجتماعي يطرح تحدياً جديدة تختلف عن تلك الموجودة في وسائل الإعلام التقليدية. فعلى عكس المقالات الإخبارية، فإن التغريدات تكون مقيدة الطول مما يجعل المعلومات النصية فيها محدودة. كما تشمل كميات كبيرة من الكلمات غير الرسمية والأخطاء الإملائية، وهياكلها غير المنظمة. وتحتوي أيضاً على كميات من الرسائل الوهمية والشائعات (Q. Li et al., 2022).

1.1.1 الإطار العام للمسألة

نستطيع النظر إلى مسألة كشف الأحداث من عدة زوايا، استناداً إلى نوع الحدث، يمكننا تصنيف هذه الطرق إلى اكتشاف حدث غير محدد وحدث محدد Unspecified Vs. Specified. وفي مجال ال TDT، يصنف كشف الأحداث إلى فئتين (1) كشف الأحداث الجديدة (NED) New Event Detection و (2) كشف الأحداث الرجعية Retrospective Event Detection (RED). Event Detection ففي حالة NED يكون هدفنا هو اكتشاف الأحداث الجديدة في دفع بيانات في الزمن الحقيقي، بينما في حالة RED فإننا نركز على التعرف واكتشاف الأحداث في بيانات تاريخية (Q. Li et al., 2022).

يمكننا الآن مناقشة كل نوع على حدى، فنبداً إذن بالتصنيف القائم على النوع:

♣ كشف الحدث المحدد Specified Event Detection

في هذا النوع من الأحداث يكون لدينا علم مسبق بمكان وزمان وقوع الحدث. أي عندما يكون الحدث الاجتماعي معروفاً أو مخططاً له بالفعل، فإن معالجة البيانات المتعلقة بالمعلومات المعروفة (مثل الموقع والوقت والكلمات الرئيسية والمستخدمين) لاستخراج وصف الحدث تسمى اكتشاف الأحداث المحددة (SED). ويعالج في هذا النوع، المعلومات المحددة مسبقاً والميزات التي من المتوقع أن تظهر في البيانات لتمثيل حدث. تعمل هذه المعلومات المحددة مسبقاً كبذرة لسياق الحدث الفعلي. يمكن التعبير عن المعلومات المتعلقة بالحدث كلياً أو جزئياً لجمع البيانات وتحليلها (Q. Li et al., 2022).

♣ كشف الحدث غير المحدد Unspecified Event Detection

في هذا النوع من الأحداث، لا علم لنا بمكان وزمان وقوع الحدث ولا بطبيعته، فعندها يكون مصدرنا الوحيد لتحديد هو مراقبة الخصائص الزمانية والكلمات المنتشرة. أي عندما تكون المعلومات الاجتماعية حول حدث ما غير معروفة، يعتمد النهج الأساسي ل UED على تحليل الأنماط الزمنية لتدفق البيانات من خلال مراقبة التدفق لتحديد الكلمات الرئيسية والمفاهيم المتكررة ذات الصلة بتسليط الضوء على الأحداث (Q. Li et al., 2022).


أما بالنسبة للتصنيف الثاني:

♣ كشف الأحداث الجديدة والرجعية New Event Detection & Retrospective Event Detection

اعتماد على المهمة ونوع الحدث، يمكننا أيضاً تصنيف الحدث إلى نوعين NED و RED. ونظراً لأن تقنيات NED تتضمن المراقبة المستمرة لتدفق البيانات لكشف الأحداث الجديدة في الزمن الفعلي، فإنه يكون مناسباً بطبيعته لكشف أحداث العالم الحقيقي غير المعروفة والأخبار العاجلة. كما يمكن استخدام تقنيات ال NED من أجل كشف الأحداث المحددة، على الرغم من أن معظم الدراسات تركت على الأحداث غير المحددة. وعندما تتضمن المهمة المرادة أحداثاً محددة أو معلومات محددة


حول الحدث (عل سبيل المثال، منظمة محددة، شخص أو مكان ما) يمكن الاستفادة من هذه المعلومات لمكاملتها مع تقنيات ال NED من خلال تقنيات الفلترة أو التصنيف.

كما ويوضح الشكل أدناه بعض نطاقات المعالجة المهمة (تجزئة، فلترة، عنقدة) وذلك حسب نمط المسألة. أي إذا كنا نهتم بجميع الأحداث أو إذا كانت جميع الرسائل تنتمي إلى أحداث (Schinas et al., 2018).



الشكل 3: نطاقات معالجة كشف الأحداث حسب نمطها (Schinas et al., 2018).

ويختصر الشكل أدناه مفردات المسألة ويصنفها بشكل هرمي يوضحها.



الشكل 4: تصنيف هرمي للأحداث (Saeed, Abbasi, Maqbool, et al., 2019).

1.1.1 المراحل الرئيسية لسير العمل في نظام لكشف الأحداث

يقسم Li وآخرون في بحثهم مراحل عمل نظام كشف الأحداث لثلاثة مراحل كما هو موضح في الشكل أدناه، هي (1) مرحلة المعالجة المسبقة والتي تتم على دفع البيانات الذي يرد إلى النظام، (2) مرحلة كشف الأحداث، (3) مرحلة مابعد كشف الحدث.




Figure 1 : The typical workflow for a NED system for unspecified events (Q. Li et al., 2022).

ومهمة كل مرحلة هي كما يلي:

- ♣ مرحلة المعالجة المسبقة Preprocessing Stage، تحوي هذه المرحلة عدة مكونات مثل مكون فلتر الضجيج الذي يقوم بإزالة الرسائل غير المهمة، الإعلانات وماشابه. وتحتوي على مكونات لاستخراج الكيانات، المعلومات الجغرافية.
- ♣ مرحلة كشف الحدث Event Detection Stage، اعتماداً على نوع الحدث المراد كشفه (Specified, Unspecified, RED, NED) قد تختلف تقنية الكشف الفعلية (على سبيل المثال، الطرق المعتمدة على العقدة، المعتمدة على المصطلحات، ...). وتهدف مكونات Event Cluster Defragmentation إلى دمج مجموعات الأحداث ذات الصلة، و Purging Event إلى إزالة الأحداث القديمة التي لم يعد هناك حاجة إليها.
- ♣ مرحلة مابعد الكشف Post-Detection Stage، حسب التطبيق الذي نهتم به، قد نحتاج إلى بعض المكونات مثل تلخيص الأحداث Event Summarization، تحديد الموضوع Topic Detection، كشف الشائعات.

1.1.1 تعريف المسألة Problem Definition

أ- تعريف: دفع البيانات الاجتماعي A Social Stream

نعرف دفع البيانات $\mathcal{S}$ على أنه تسلسل مرتب زمنياً ومستمر لكتل الرسائل الاجتماعية Social Messages Blocks، ممثلة كـ $\mathcal{S} = M_0, \dots, M_{i-1}, M_i, \dots$ حيث كل كتلة رسائل M_i تحوي كل الرسائل التي وصلت خلال الشريحة الزمنية $[t_i, t_{i+1}]$ أي M_i هي مجموعة من الرسائل الفردية، أي $M_i = \{m_j; 1 \leq j \leq |M_i|\}$ ، حيث كل رسالة m_j تحوي نص الرسالة بالإضافة إلى المرسل وزمن الإرسال (Abagissa et al., 2024).

ب- تعريف: الحدث An Event

نرمز له بـ e ، وهو مجموعة من الرسائل الاجتماعية المترابطة المرتبطة بحدث في العالم الحقيقي. ونفترض أن كل رسالة مرتبط بحدث اجتماعي واحد على الأكثر. أي $e = \{m_j; 1 \leq j \leq |e|\}$ (Abagissa et al., 2024).

ت- تعريف: خوارزمية كشف الأحداث Event Detection Algorithm

من أجل كتلة رسائل M_i ، يتم تدريب خوارزمية كشف الأحداث Social ED Algorithm لتعلم نموذج $\mathcal{F}$ ، بحيث $\mathcal{F}(M_i; \theta) = E_i$ حيث E_i هي مجموعة الأحداث التي تظهر في الكتلة M_i . أي $E_i = \{e_j; 1 \leq j \leq |E_i|\}$. و θ هو موسط كدخل للنموذج (Abagissa et al., 2024).

1.1.1 طرق معالجة المسألة

هنالك تنوع كبير في منهجيات كشف الأحداث، ونستطيع تصنيف هذه المنهجيات إلى أربع فئات اعتماداً على مبدأ عملهم:

♣ مرتكزة على السمة Feature-Pivot، تعتمد هذه الطرائق على كشف أنماط غير طبيعية في بعض سمات النص (على سبيل المثال، بعض العبارات المتفجرة Bursty Phrases)، أي عندما يقع حدث ما فإن بعض الكلمات والعبارات سيتم تداولها بشكل كثير مما يجعل توزيعها غير طبيعي بالنسبة لتوزيعها تاريخياً، وبناءً على ذلك يتم الكشف.

♣ مرتكزة على المستند Document-Pivot، تعتمد هذه الطرائق على تحويل المستند (message & its meta data) إلى شعاع، ومن ثم عنقدة الأشعة وتجميعها بناءً على التشابه. وفي عدد من الدراسات الحديثة، تم تعزيز هذه المنهجية باستخدام الشبكات العصبية البيانية (GNNs)، حيث يتم الاستفادة من شبكات المعلومات غير المتجانسة لتحويل بيانات وسائل التواصل الاجتماعي من شكلها غير المهيكل إلى شكل مهيكل ذو علاقات دلالية، ومن ثم الاستفادة من البيان الناتج ومن قدرات GNNs في تمثيل العلاقات غير الخطية والتفاعلات المعقدة بين الكيانات. لتحسين وزيادة فعالية تمثيل اشعة التضمين، على سبيل المثال، وظفت أبحاث مثل (KPGNN - Cao et al., 2021)، و (HCRC - Guo et al., 2024) و (QSGNN - Ren et al., 2022)* تقنيات GNNs.

♣ مرتكزة على الموضوع Topic-Pivot، تضمن هذه الطرائق استخدام نماذج إحصائية لكشف الحدث على اعتباره متحول ضمني في المستند. (Schinas et al., 2018).

وفي بعض الأبحاث لجاء الباحثون إلى طريقة قائمة على البيان Graph Based، حيث يتم الاستفادة من الهيكلية الدلالية للرسائل ضمن وسائل التواصل الاجتماعي حيث يتم تحويل مجموعة الرسائل غير المهيكلة Unstructured Messages إلى رسائل مهيكلة ذات دلالة Semantic Structured Data (وذلك باستخدام الكيانات المسماة، hashtags، عمليات الذكر) وذلك بإنشاء بيان، وبعد إنشاء هذا البيان تتحول المسألة حينها على مسألة تجزئة البيان Graph Partitioning.

1.1.1 المنهجيات والمقاربات لمعالجة المسألة

يوضح الجدول أدناه الأبحاث ذات الصلة والمقاربات المتبعة لكشف الأحداث في وسائل التواصل الاجتماعي.


#	Paper (Name)	Techniques	Reference	Supervision	Event Type	Detection Task
1	Petrović et al., 2010	Online Clustering & LSH	(Petrović et al., 2010)	Unsupervised	U	NED
2	Sakaki et al., 2010	SVM	(Sakaki et al., 2010)	Supervised	S	RED
3	Long et al., 2011	Hierarchical Clustering	(Long et al., 2011)	Unsupervised	U	NED
4	Cordeiro, 2012	Wavelet Analysis & LDA	(Cordeiro, 2012)	Unsupervised	U	NED
5	McCreadie et al., 2013	K-Mean Clustering & LSH	(McCreadie et al., 2013)	Unsupervised	U	NED
6	Corney et al., 2014	Online Clustering	(Corney et al., 2014)	Unsupervised	S	NED
7	Alsaedi et al., 2015	Online Clustering	(Alsaedi et al., 2015)	Unsupervised	U	NED
8	Patil et al., 2015	NN Classification	(Patil et al., 2015)	Supervised	S	-
9	Guille & Favre, 2015	Mention, Anomaly Detection	(Guille & Favre, 2015)	Unsupervised	U	NED
10	Zhang et al., 2016	Spatial-temporal Clustering	(C. Zhang et al., 2016)	Unsupervised	U	NED
11	Alsaedi et al., 2016	Temporal, Spatial, Textual Features, Online Clustering	(Alsaedi et al., 2016)	Unsupervised	U	NED
12	Hasan et al., 2016 (TwitterNews)	Incremental Clustering	(Hasan et al., 2016)	Unsupervised	U	NED

13	Chen et al., 2017	NN, Online Clustering			U	NED
14	Zhang et al., 2017	Spatial-Temporal Clustering	(S. Zhang et al., 2017)	Unsupervised	U	NED
15	Edouard, 2018	Domain Vocabulary and Knowledge Based	(Edouard, 2018)	Supervised	S	NED
16	Comito et al., 2019	Text & Temporal Feature Clustering	(Comito et al., 2019)	Unsupervised	U	NED
17	Hossny et al., 2019	Keyword Volume Approach, SVM	(Hossny & Mitchell, 2019)	Supervised	S	NED
18	Fedoryszak et al., 2019	Cluster Chain, Graph	(Fedoryszak et al., 2019)	Unsupervised	U	NED
19	Nguyen et al., 2019	Entity Clustering	(Nguyen et al., 2019)	Unsupervised	U	NED
20	Saeed et al., 2019	Graph, Clustering	(Saeed, Abbasi, Razzak, et al., 2019)	Unsupervised	U	NED
21	Morabia et al, 2019 (SEDTWik)	Segments, Hierarchical Clustering	(Morabia et al., n.d.)	Unsupervised	U	NED
22	Liu et al., 2020 (EventX)	Community Detection		Unsupervised	U	NED
23	Cao et al., 2020 (IED KCN)	Knowledge Consolidation Network (KCN)	(P. Cao et al., 2020)	Supervised	-	NED
24	Li and Zhang, 2021	Semantic Term, GCN, Clustering	(Q. Li & Zhang, 2021)		U	NED
25	Ghaemi et al., 2021	Spatial-Temporal Clustering, VDBSCAN	(Ghaemi & Farnaghi, 2023)	Unsupervised	U	NED
26	Cao et al., 2021 (KPGNN)	GNN, Clustering	(Y. Cao et al., 2021)	Supervised	-	NED
27	George et al., 2021	Spatial-Temporal Clustering	(George et al., 2021)	Unsupervised	U	NED
28	Mojiri et al., 2021	Burst Keywords, Time Series Analysis	(Mojiri et al., 2021)	Unsupervised	U	NED
29	Yamani et al., 2021	Knowledge Based, MLM	(Yamani et al., n.d.)	Supervised	-	-
30	Peng et al., 2022 (FineEvent)	GNNs	(Peng et al., 2023)	-	-	-
31	Hettiarachchi et al., 2022 (Embed2Detect)	NN, hierarchical clustering	(Hettiarachchi et al., 2022)	Unsupervised	U	NED
32	Afyouni Khan et al., 2022	Spatial-Temporal Clustering, Classification	(Afyouni, Khan, et al., 2022)	-	U	NED

33	Ren et al., 2022 (QSGNN)	GNNs, Online Clustering	(Ren et al., 2022)	Supervised	-	-
34	Bok et al., 2023	Graph, Online Clustering	(Bok et al., 2023)	Unsupervised	U	NED
35	Cao et al., 2024 (HISEvent)	GNNs, Graph Clustering	(Y. Cao et al., 2023)	Unsupervised	U	
36	Yue et al., 2023	MLM	(Yue et al., 2023)	Supervised	-	-
37	Pradhan et al., 2024 (EDTBert)	Graph Clustering, PLMs	(Pradhan et al., 2024)			
38	Guo et al., 2024 (HCRC)	GNNs, Incremental Clustering	(Guo et al., 2024)	Unsupervised	U	NED
39	Ray et al., 2024	Incremental Clustering	(Ray et al., 2024)	Unsupervised	U	NED
40	P. Li et al., 2024 (RPLMSED)	PLMs	(P. Li et al., 2024)	Supervised	S	NED
41	Abagissa et al., 2024 (DistilBert – GNN)	GNNs, Clustering	(Abagissa et al., 2024)	-	U	NED
42	Yang et al., 2024 (ADPSEM)	Structural Entropy Minimization	(Yang et al., 2024)	Unsupervised	-	-
43	Yu et al., 2024 (HyperSED)	Hyperbolic Embedding, Graph Partitioning	(Yu et al., 2024)	Unsupervised	U	NED
44	Kovalchuk et al., 2025 (SemConvTree)	Semantic Convolutional Tree	(Kovalchuk et al., 2024)	Unsupervised	U	NED


1.1.1 النموذج HCRC

تم في هذه الورقة اقتراح طريقة جديدة للكشف عن الأحداث بطريقة غير خاضعة للإشراف من خلال التعلم المقارن للبيان الهجين (hybrid graph contrastive learning)، حيث يتم استخدام التعلم المقارن على البيان لتعلم معلومات تمييزية للرسائل. ويوضح الشكل أدناه البيئة العامة للنموذج، حيث يتم تعلم التضمين على مستويين، مستوى البيان، ومستوى العقدة.



ويتم ذلك وفق التالي، عندما تصل كتلة رسائل M_i ، يتم تنفيذ مسار العمل الموضح بالشكل أدناه.

- حيث نبدأ بإنشاء البيان من الرسائل، نبدأ من بيان رسائل غير متجانس يحوي الرسائل وكياناتها المسماة، ومن ثم يتم تحويله إلى بيان متجانس يحوي الرسائل فقط، وبعد ذلك تبدأ عملية تعلم مقارنة على البيان
- يتم هذا على مستويين -مستوى البيان ومستوى العقدة - في مستوى البيان يتم تشكيل Social Message Attribute Graphs كل واحد منها على شكل نجمة حيث لكل رسالة يكون في المركز الرسالة وترتبط مع الكيانات المسماة الموجودة بها ويتم تعزيز البيان بعد لك وإجراء تعلم مقارنة من أجل تعلم التضمين، وفي مستوى العقدة يتم تشكيل Social Message Relation Graph يحوي الرسائل ووصلات بينها بناءً على مدى تشاركها بالكيانات المسماة وبعد ذلك يتم تعزيز البيان وإجراء تعلم مقارنة لتعلم التضمين)، من ثم تجري عملية عنقدة باستخدام خوارزمية SinglePass.
- يتم إنشاء العينات الموجبة على مستوى البيان، من خلال حذف وإضافة وصلات عشوائية بين العقدة وكياناتها المسماة، واعتبار البيانين هما متشابهان، اعتبار بقية البيانات هم العينات السالبة.



الشكل 5: خط عمل النموذج HCRC.

1.1.1 معايير التقييم وقياس الأداء

أ. Normalized Mutual Information (NMI)

المعلومات المتبادل المعيرة، يقيس مقدار المعلومات المشتركة بين المجموعات الحقيقية (Ground Truth) والمجموعات المكتشفة (Predicted Clusters). يتم تقيسه باستخدام الإنتروبي ليصبح المقياس بين 0 و 1. وهو مفيد لتقييم جودة العنقدة مع أخذ احتمالية الاتفاق العشوائي بعين الاعتبار.

$$NMI(U, V) = \frac{I(U; V)}{H(U) + H(V)}$$

حيث $I(U; V)$ هي المعلومات المتبادلة بين المجموعتين $H(U)$ ، $H(V)$ هي الإنتروبي لكل من المجموعات الحقيقية والمتوقعة.

ب. Adjusted Mutual Information (AMI)

مقياس معدل من NMI يأخذ بالحسبان مقدار المعلومات المتبادلة المتوقعة (Expected Mutual Information) عند التوزيع العشوائي للتسميات. بالتالي، يوفر مقياسًا أكثر دقة في الحالات التي يكون فيها الاتفاق العشوائي مرتفعًا.

$$AMI(U, V) = \frac{I(U; V) - \mathbb{E}[T(U; V)]}{\max(H(U), H(V)) - \mathbb{E}[T(U; V)]}$$

ت. B-Cubed

مقاييس B-Cubed Precision و B-Cubed Recall تستخدم لتقييم نتائج العنقدة (Clustering) بحيث تأخذ بعين الاعتبار كل عنصر ومقارنته مع عناصر أخرى في نفس المجموعة. أي بعكس المقاييس الأخرى التي تقيم التوزيع الكامل للمجموعات دفعة واحدة، يقوم B-Cubed بتقييم كل عنصر على حدة، ويحسب دقة واسترجاعه بناءً على الانتماءات الفعلية والمتوقعة.

1.1.1 مجموعات البيانات المتاحة

يوضح الجدول أدناه مجموعات البيانات المتاحة والمستخدمه في معظم المراجع لتدريب النماذج لهذه المسألة وقياس أدائها.

جدول 1 : مجموعات البيانات المتاحة لمسألة كشف الأحداث.

	Dataset	Size	Events	Language	Paper
1	Kawarith	~9K tweet	7	Arabic	(Alharbi & Lee, n.d.)
2	Events 2012	~68K tweet	503	English	(McMinn et al., 2013)
3	Maven	~10K tweet	164	English	(Wang et al., 2020)
4	Events 2018	~64K twee	257	French	-
5	FA Cup	~670K tweet		English	-
6	CrisisLex	~60K tweet	6	English	(Olteanu et al., 2014)
7	Few Events	~8K tweet	64	English	
8	KBP	~85K tweet	100	English	(Deng et al., 2020)
9	FloDust	~20K tweet	3	Arabic	(Hamoui et al., 2021)
10	CrisisMMD	~18K tweet	7	English	-

كما ويوضح الجدول أدناه مجموعات البيانات التي تم استخدامها في الأبحاث، حيث يلاحظ أن معظم الأبحاث تعتمد على مجموعة بيانات خاصة بالبحث (غير متوفرة).

جدول 2 : مجموعات البيانات المستخدمة في الأبحاث المدروسة.


	Paper Dataset	Events 2012	Events 2018	Maven	Few Events	CrisisLex	Kawarith	FA Cup	Other	Private
1	Petrović et al., 2010								Y	
2	Sakaki et al., 2010									Y
3	Long et al., 2011									Y
4	Cordeiro, 2012									Y
5	McCreadie et al., 2013									Y
6	Corney et al., 2014									Y
8	Alsaedi et al. , 2015									Y
9	Zhang et al. , 2017									Y
10	Hossny et al. , 2019									Y
11	Saeed et al. , 2019							Y	Y	
12	Fedoryszak et al. ,2019	Y								
13	Morabia et al. ,2019	Y								
14	Zhang et al.,2021									Y
15	Hettiarachchi et al. ,2021							Y		
16	Ghaemi et al. ,2021									Y
17	Mojiri et al. ,2021							Y	Y	

	Paper Dataset	Events 2012	Events 2018	Maven	Few Events	CrisisLex	Kawarith	FA Cup	Other	Private
18	Yamani et al. ,2021								Y	
19	Cao et al. ,2021	Y		Y						
20	Peng et al. ,2021								Y	
21	Afyouni et al. ,2022									Y
22	Ren et al. ,2022	Y	Y							
23	Kolajo et al. ,2022									Y
24	Peng et al. ,2022									Y
25	Bok et al. ,2023									Y
26	Cao et al. ,2023	Y	Y							
27	Ren et al. ,2023 a	Y	Y				Y			
28	Ren et al. ,2023 b	Y	Y			Y				
29	Guoa et al. ,2023			Y						
30	Yue et al. ,2023			Y	Y					
31	Yang et al. ,2024	Y	Y							
32	Qiu et al. ,2024	Y				Y	Y			
33	Ray et al. ,2024	Y	Y							
34	Yu et al. ,2024	Y	Y				Y		Y	
36	Abagissa et al. ,2024	Y								
37	Pradhana et al. ,2024							Y	Y	
38	Ma et al. ,2024	Y	Y		Y	Y	Y			
39	Li et al. ,2024	Y	Y				Y			
40	Kovalchuk et al. ,2024 a									Y
41	Kovalchuk et al. ,2024 b	Y							Y	
42	Kargupta et al. ,2024									Y
43	Murthy et al. ,2025									Y

3.1- مسألة الاستدلال على الموقع الجغرافي من النص


1.1.1 الإطار العام للمسألة

يعرف الاستدلال على الموقع من النصوص الفردية -ويسمى أيضاً (GeoParsing)- بعملية تقدير الإحداثيات الجغرافية للنص بناءً على محتواها أو بياناتها الوصفية أو كليهما. ونظراً لأن نسبة ضئيلة فقط من النصوص في مواقع التواصل الاجتماعي تحمل علامات جغرافية صريحة geotag in metadata فعلى سبيل المثال، في منصة تويتر فقط 3% من التغريدات تحمل علامات جغرافية صريحة، ولذلك يعتمد الباحثون على المعلومات المستخرجة من اللغة الطبيعية - مثل أسماء الأماكن المذكورة في نص التغريدة - بالإضافة إلى المعلومات السياقية مثل الوسوم المعلومات الزمنية وبيانات المستخدم. ويتكون نظام الاستدلال على الموقع الجغرافي من عمليتين هما (1) التعرف على الموقع المذكور (Location Mention Recognition (LMR)، و (2) تحديد الموقع وفك غموضه (Location Mention Disambiguation and Detection (LMD). وبالنسبة لعملية التعرف على الموقع المذكور LMR والتي تسمى في بعض المراجع أيضاً بـ Toponym Recognition وهو حالة خاصة من مسألة التعرف على الكيانات المسماة (NER) Named Entities Recognition حيث يتم فيها تحديد الكلمات التي تدل على الموقع واستخراجها. أما في عملية تحديد الموقع وفك غموضه والتي أيضاً تسمى في بعض المراجع بـ Toponym Resolution، ففيها يتم تحويل المواقع المستخرجة من المرحلة السابقة إلى إحداثيات جغرافية أو معرفات في قاموس جغرافي Gazetteer، وذلك بعد فك الغموض الذي يحدث نتيجة وجود عدد من العناوين المتشابهة (مثل مدينة بانباس في محافظة طرطوس، ومدينة بانباس في محافظة القنيطرة) التي تحل من خلال أخذ المعلومات السياقية بالاعتبار أو من خلال بعض التجريبيات. ويوضح الشكل أدناه آلية العمل تلك بشكل عام.



رسم توضيحي 2: مخطط العمل العام ضمن نظام استدلال الموقع (Afyouni, Aghbari, et al., 2022).


كما يصنف الباحثون مصادر المعلومات المستخدمة للاستدلال على الموقع، إلى فرعين، الأول استخراج مباشر يتم عن طريق استخراج المعلومات المكانية الموسومة من ملف المستخدم الشخصي أو عن طريق المعلومات المكانية الموسومة مع النص المنشور حيث تقدم بعض وسائل التواصل مثل تويتر وسوم مكانية في حال قفل المستخدم الـ GPS، والفرع الثاني هو غير مباشر ويكون إما عن طريق الاستدلال من خلال النص المنشور (وهو المناسب في حالتنا) أو عن طريق تحليل المحتوى المرئي (مثل الصور) وهذا لن نتطرق له في حالتنا. والشكل أدناه يوضح هذه الأنماط.



الشكل 6: أنماط لاستدلال على الموقع الجغرافي (Afyouni et al., 2022).

1.1.1 المنهجيات والمقاربات المتبعة للتعرف على الموقع

تصنف المقاربات المتبعة للتعرف على الموقع ضمن أربع أنماط هي (1) معتمدة على القواعد، (2) معتمدة على المطابقة من Gazeteer، (3) معتمدة على التعلم، (4) طرق هجينة بين الثلاث السابقة.



الشكل 7: تصنيف طرائق التعرف على الموقع.

❖ مقاربات قائمة على القواعد Rule-Based Approaches: في هذا النمط من الأنماط يتم معالجة المسألة من خلال الأنماط المنتظمة Regular Expressions، وذلك لأن الموقع الذي يذكر في النص غالباً ما يحتوي على سمات تميزه لذلك يتم الاعتماد على قواعد (سواء كانت موضوعية من قبل خبراء، أم تم تعلمها) لاستخراج النص الذي يشير إلى موقع، وهذه الطرق قليلة الاستخدام نظراً لأن النص المكتوب في وسائل التواصل الاجتماعي يحوي على ميزات تجعل تطبيق هذا النوع غير مجدي، ولكن تبقى هذه الطرق مستخدمة لتحسين أداء المقاربات الأخرى عند استخدامها معها.

- ❖ مقاربات مطابقة القاموس الجغرافي Gazetteer Matching Approaches: في المقاربات القائمة على المطابقة من قاموس جغرافي، يعتمد الباحثون في هذه المقاربة على أخذ الـ n-gram للنص، ومن ثم لكل سلسلة يقومون بمحاولة لمطابقتها مع القاموس الجغرافي، وبعد ذلك يتم فلتر النتائج وفك غموضها بناء على مجموعة تجريبية heuristics.
- ❖ مقاربات التعلم Statistical Learning Approaches: في هذه الطرائق يتم الاعتماد على تعلم الآلة Machine Learning وعلى مدونة منمطة، لتعلم نموذج يقوم بتصنيف المفردات في النص. وفي معظم الأبحاث يقوم الباحثون بالاعتماد على نماذج التعرف على الكيانات المسماة NER ومن ثم ضبطها وتدريبها على هذه المسألة Fine-Tuning، وفي أبحاث أخرى كما (Chen et al., Bobadilla et al., Cadorel et al.) يقوم الباحثون بالتعامل مع المسألة بشكل منفصل عن NER وتدريب نماذجهم لهذه المسألة خصيصاً.
- ❖ المقاربات الهجينة Hybrid Approaches: في هذا النوع يلجأ الباحثون إلى استخدام المقاربات السابقة مع بعضها البعض بحيث يتم الاستفادة من ميزات كل مقاربة لتحسين الحل المقترح.

1.1.1 استخدام نماذج اللغة الكبيرة لاستدلال الموقع المذكور

لقد عزز ظهور نماذج اللغة الضخمة (LLMs) بشكل كبير قدرة الآلة على فهم استفسارات المستخدم المعقدة، وعزز فعالية معالجة اللغة وفهمها لها، مما أفاد العديد من المجالات، بما في ذلك مجال العلوم الجغرافية المكانية. وقد بحثت العديد من الدراسات في إمكانيات وقيود نماذج اللغة الضخمة في هذا المجال (Ji and Gao 2023, Mooney et al. 2023, Tao and Xu 2023, Xie et al. 2023, Yin et al. 2023, Hochmair et al. 2024). فعلى سبيل المثال، درس Xie وآخرون حدود تطبيق نماذج الذكاء الاصطناعي في السياقات الجغرافية المكانية، ودعوا إلى نماذج ذات أساس جغرافي مُصممة خصيصاً لها. حيث يسلط هذا البحث الضوء على الاختلاف بين أنواع البيانات التقليدية، مثل نصوص اللغة الطبيعية والفيديو، التي صُممت من أجلها نماذج الذكاء الاصطناعي، والبيانات الجغرافية المكانية، مُشيراً إلى ضرورة الابتكار في هذا المجال. وقَّيمَ Ji و Gao مدى كفاءة نماذج اللغة الضخمة في تفسير وتمثيل المفاهيم المكانية المذكورة في النصوص. وقرن Hochmair وآخرون أداء نماذج ChatGPT-4 و Bard و Claude-2 و Copilot في مهام جغرافية مكانية مُختلفة، مثل فك الغموض المكاني، ومفاهيم نظم المعلومات الجغرافية، ورسم الخرائط. كما واستكشف Juhasz وآخرون إمكانية استخدام GPT 3.5-turbo لإثراء Open Street Map (OSM) من خلال اقتراح أفضل الوسوم لكل طريق في OSM بناءً على أوصاف مشتقة من صور Mapillary. وبعض الأبحاث أيضاً حول تطبيق نماذج اللغة الضخمة (LLM) في التحليل الجغرافي، على سبيل المثال، قدّم Li وآخرون نموذج لغة مكاني GeoLM، وهو مدرب مسبقاً باستخدام بيانات من مصادر مثل ويكيبيديا و Wikidata و OpenStreetMap. يمكن تكييف GeoLM لدعم مهام متعددة في مراكز المدن، مثل التعرف على أسماء المواقع الجغرافية، والتحليل، واستخراج العلاقات، وكتابة الكيانات الجغرافية. كما واستكشف Mai وآخرون إمكانية الاستفادة من نماذج اللغة الضخمة، في مجال الذكاء الاصطناعي الجغرافي. وأثبتوا أن نماذج اللغة الضخمة تتفوق على النماذج المخصصة لمهام محددة في مهام الدلالات

الجغرافية المكانية، بما في ذلك التعرف على أسماء المواقع الجغرافية والتعرف على وصف الموقع. وقام أيضاً Hu وآخرون بدراسة جدوى نماذج GPT المختلفة، لاستخراج أوصاف المواقع من وسائل التواصل الاجتماعي أثناء الكوارث. وقارنوا هذه النماذج بأدوات التعرف على الكيانات المسماة (NER) التقليدية ونموذج BERT المعدل. استخدمت الدراسة مجموعة بيانات من التغريدات المنمطة من إعصار هارفي. وتُظهر النتائج أن نماذج GPT الموجهة بالمعرفة الجغرافية تفوقت بشكل ملحوظ على أدوات NER ونموذج BERT المعدل في التعرف على أوصاف المواقع الكاملة والفئات المرتبطة بها. كما وقيم Hu وآخرون أداء نماذج اللغة الضخمة المخففة Lightweight في مهمة التعرف على الموقع المذكور وفك الغموض.

1.1.1 تعريف المسألة Problem Definition

كما ذكرنا آنفاً أنّ المسألة تتكون من جزئين التعرف على الموقع المذكور (LMR)، وتحديد الموقع وفك الغموض (LMD)، ونستطيع صياغة المسألة لهما بشكل رياضي كما يلي:

١) تصاغ مسألة التعرف على الموقع المذكور كما يلي

ليكن لدينا نص t ، يهدف نظام LMR إلى تحديد جميع المواقع المذكورة في النص $L_t = \{l_i; i \in [1, n_t]\}$ حيث n_t هي العدد الكلي للمواقع المذكورة في النص t . وكل l_i قد تغطي أكثر من مفردة في النص لذلك يتم استخدام نموذج الموسم BILOU، حيث B توسم بداية الموقع و I توسم أننا ضمن ذكر موقع و L توسم نهاية ذكر الموقع و O أن المفردة خارج الرمز بينما ترمز U إلى أن ذكر الموقع يغطي مفردة واحدة فقط (Suwaileh et al., 2023).

٢) تصاغ مسألة تحديد الموقع وفك غموضه كما يلي

بعد أن يتم التعرف على جميع المواقع المذكورة في النص $L_t = \{l_i; i \in [1, n_t]\}$ ، يتم هنا ربط كل ذكر موقع l_i بتمثيل جغرافي دقيق وفريد، وهو يكون إما عبارة عن إحداثيات ($latitude, longitude$) أو معرف في قاعدة بيانات جغرافية. تُعرف هذه المسألة رياضياً كتابع $LMD : L \rightarrow G$ ، حيث L هو مجموعة المواقع المذكورة المستخرجة من النص t ، G هي مجموعة الكيانات الجغرافية الممكنة (على سبيل المثال، Gazeeter)، حيث تعطي لكل مدخل جغرافي إحداثياته ($latitude, longitude$). حيث يهدف التابع LMD إلى إيجاد المطابقة الأمثل لكل l_i بحيث يُسند إلى l_i الكيان الجغرافي $g \in G$ الذي يمثل بدقة المقصود في السياق النصي (Suwaileh et al., 2023).

1.1.1 مجموعات البيانات المتاحة

يوضح الجدول أدناه مجموعات البيانات المتاحة والمستخدمه في معظم المراجع لتدريب النماذج لهذه المسألة وقياس أدائها.

جدول 3: مجموعات البيانات المتاحة لمسألة التعرف على الموقع المذكور

	Dataset	Size	Region	Language	Paper
1	IDRISI-R (Gold)	~20K En, ~4.6K Ar	Global (41 disaster events)	Ar, En	(Suwaileh et al., 2023)
2	IDRISI-R (Silver)	~57K En, ~1.2M Ar	Global (41 disaster events)	Ar, En	(Suwaileh et al., 2023)
3	GeoCorpora	~6,648 tweets	USA	En	
4	GeoCoV19	~524M tweets	Global (COVID-19 related)	Multilingual	(Qazi et al., 2020)
5	UTGEO	~670K tweets	USA	Multilingual	
6	TweeLoc	~325K tweets	Rome, Netherlands	Un Specified	

1.1.1 معايير التقييم وقياس الأداء


من أجل تقييم النتائج لهذه المسألة وقياس أداء النماذج يوجد العديد من معايير التقييم، التي تختلف حسب الهدف من النموذج فمن أجل النماذج التي تهدف إلى التنبؤ بـ (المنطقة، المدينة، ...) فيتم في هذه الحالة استخدام المعايير التقليدية كالصحة، الدقة والاستدكار (Accuracy, Precision, Recall)، أي يتم التعامل معاً كمسألة تصنيف طبيعية. (أي هي مناسبة في حالة التعرف على الموقع المذكور (LMR))، أما بالنسبة للنماذج التي تتنبأ بالإحداثيات الجغرافية للرسالة، ففي هذه الحالة يتم استخدام معايير التقييم المستخدمة لمسائل الانحدار متوسط خطأ المسافة Mean Error Distance، الصحة في الكيلومتر Accuracy@KM (أي بتكميم المسألة وتحويلها إلى تصنيف ضمن خلايا)، مسافة هافيرسين (Haversin Distance) وهي صيغة مسافة بين الإحداثيات الجغرافية ويستخدم لقياس المسافة على سطح الأرض، وصيغته هي كما هو موضح أدناه.

4.1- أنظمة مشابهة

يوجد عدد من المنصات التي تعالج المسألة المطروحة سواء بشكل شبه كامل أو جزء منها، على مستويات مختلفة، أي يوجد بعض المنصات التي تعالج المسألة على مستوى عالمي وأخرى على مستوى محلي.

1.4.1 Liveuamap.com Live Universal Awareness Map

خريطة الوعي العالمي الحي، هو موقع إلكتروني تفاعلي يعرض خريطة عالمية تحتوي على أخبار وأحداث جارية يتم تحديد مواقعها جغرافيًا. المنصة تُستخدم لتتبع الأحداث السياسية، العسكرية، الكوارث الطبيعية، وأخبار الأمن والنزاعات في الوقت الحقيقي، حيث يسمح للمستخدم بتحديد نوع الأحداث التي يريد الاطلاع عليها (كوارث طبيعية، نزاعات، ...) ومن ثم يعرض عليها بشكل حي هذه الأحداث ويتم تحديث المعلومات بالزمن شبه الحقيقي. حيث يعد مصدرًا قيمًا للمعلومات، ويوفر وصولاً مفتوحًا عبر الإنترنت إلى أرشيف زمني كامل للمعلومات، مما يتيح للمشاهدين البحث في الأحداث الماضية والاتجاهات التاريخية



♣ كيف يعمل الموقع؟

- يعتمد على مصادر متعددة لجمع البيانات مثل وسائل التواصل الاجتماعي، وكالات الأنباء، والمصادر المحلية.
- تستخدم المنصة خوارزميات آلية ومحررين بشريين للتحقق من صحة الأخبار وربطها بالموقع الجغرافي المناسب.
- يتم تصنيف الأحداث إلى أنواع متعددة (مثل: نزاع، سياسة، طقس، صحة، كوارث، إلخ) باستخدام رموز مختلفة.
- يمكن للمستخدمين استعراض الأخبار حسب الموقع الجغرافي، أو حسب التصنيف الزمني أو الموضوعي.


♣ كيف يجمع البيانات؟

- يعتمد على زواحف زكية AI Crawlers لتجميع البيانات وانتقاء الأخبار الجديدة بالذكر.

- يتم جمع البيانات من عدة مصادر من بينها وسائل التواصل الاجتماعي.
- بالإضافة إلى خوارزميات والنماذج، يعتمد الموقع على خبراء بشريين.

3.4.1 Globalincidentmap.com Global Incidents Map

هو موقع إلكتروني يعرض خريطة تفاعلية لحوادث وتهديدات أمنية من مختلف أنحاء العالم. يركز على التقارير المتعلقة التهديدات الأمنية، الحوادث البيولوجية، اختطاف الطائرات، وأحداث أخرى تمس الأمن العام.



صورة 1: الصفحة الرئيسية للموقع globalincidentmap.com

♣ كيف يعمل الموقع؟

- يعرض الأحداث على خريطة زمنية-مكانية تفاعلية تُحدث بشكل مستمر.
- يتم تصنيف الحوادث في فئات متعددة (مثل: تهديدات أمنية، إطلاق نار، حوادث طيران، كوارث طبيعية، إلخ).
- يمكن للمستخدمين تصفح الحوادث حسب الفئة، التاريخ، أو الموقع الجغرافي.
- يوجد عدة أنماط للموقع أحدها هو الحوادث، كما يوجد أنماط منها الكوارث الطبيعية، أزمات الغذاء، إلخ.

♣ كيف يجمع البيانات؟

- يعتمد على مزيج من المصادر الإخبارية الرسمية والمصادر المفتوحة مثل تقارير الشرطة، وكالات الأنباء العالمية.
- يتم فلتر وتصنيف البيانات من خلال أنظمة ذكية بمساعدة محررين بشريين وخوارزميات تحليل نصوص.
- بعض الخرائط يتم تحديثها يدوياً، وبعضها يتم تغذيته عبر تدفقات بيانات شبه فورية.

♣ ما الفائدة من هذا النظام؟

- أداة قوية لمتابعة التهديدات العالمية والأحداث الأمنية لحظة بلحظة.
- تُستخدم من قبل الصحفيين، مراكز الدراسات الأمنية، وفرق إدارة الأزمات.
- تُوفر تنبيهات في الوقت الحقيقي للمستخدمين المسجلين.

2.4.1 rsoe-edis.org Emergency and Disaster Information Service (EDIS)

موقع RSOE EDIS (نظام معلومات الطوارئ والكوارث)، هو خدمة تدار من قبل الجمعية الوطنية المجرية للإغاثة اللاسلكية والاتصالات، ويهدف إلى تتبع وتوثيق وتحليل الكوارث والحوادث الطارئة حول العالم. ويهدف إلى إبقاء العامة، والمنظمات الإنسانية، والباحثين، والحكومات على اطلاع دائم بالأحداث الطارئة، حيث يعرض بيانات حيّة تم جمعها من وكالات الأنباء، وسائل الإعلام، المراسد، ... إلخ، ويقوم بتحليلها وعرض الجدير بالذكر منها.



صورة 2: الصفحة الرئيسية للموقع rsoe-edis.org

♣ كيف يعمل الموقع؟

- يقوم بجمع البيانات من جهات رسمية ومنظمات إنسانية ووسائل إعلام موثوقة.
- يجمع الموقع البيانات من مجموعة كبيرة من المصادر مثل:
 - وكالات حكومية
 - وسائل الإعلام الرسمية
 - منظمات دولية
 - شبكات المتطوعين
- يوفر تقارير تفصيلية حول أنواع مختلفة من الكوارث مثل:
 - الكوارث الطبيعية (زلازل، فيضانات...)
 - التهديدات المتعلقة بالبنية التحتية
 - الحوادث البيولوجية

3.1- خلاصة الدراسة المرجعية

سنعرض هنا أهم النتائج التي توصلنا إليها من خلال دراستنا المرجعية:

❧ تعاني الطرائق المعتمدة على السمة Feature-Pivot، من أنها لا تستطيع كشف الأحداث قبل أن تصبح شائعة Trend، كما أنها غير قادرة على كشف الأحداث ذات الأثر الصغير.

❧ تكمن المشكلة الرئيسية في الطرائق المعتمدة على المستند Document-Pivot، في استخلاص معلومات تمييزية من الرسائل Extract Discriminative Information.

❧ لا يوجد مجموعة بيانات للتقييم والاختبار باللغة العربية مشابهة لمثيلاتها باللغات الأجنبية، حيث أن المجموعة الوحيدة المتوفرة هي KAWARITH تحوي على سبعة أحداث فقط وهي كوارث طبيعية. على عكس مجموعة البيانات EVENT 2012 باللغة الإنجليزية وتحوي على 506 أحداث ذات أثر متفاوت.

❧ معظم الأبحاث ركزت على مكون ما من النظام دون غيره، حيث يوجد ورقتين فقط ناقشتا النظام بكل مكوناته.

❧ استخدمت معظم الأبحاث في المقاربة الثانية Document-Pivot، خوارزمية العنقدة DBSCAN، و SinglePass

❧ تعاني خوارزمية العنقدة SinglePass، من حساسيتها الشديدة للضجيج، حيث على عكس خوارزميات العنقدة القائمة على الكثافة، فهذه الخوارزمية لاتستطع إزالة الضجيج.

الفصل الرابع

الدراسة التحليلية


يقدم هذا الفصل تحليلاً للمتطلبات التي أوردناها في الفصل الأول.

1.1- مقدمة

نقدم في هذا الفصل دراسة تحليلية للمسألة المطروحة، ونبين حالات الاستخدام ووصفها السري وبعض مخططات UML الداعمة.


3.1- مخطط حالات الاستخدام

أ- حالات الاستخدام الخاصة بالمستخدم المسجل والضيف




رسم توضيحي 3: مخطط حالات الاستخدام للضيف.

ب- حالات الاستخدام الخاصة بالمستخدم




رسم توضيحي 4: مخطط حالات الاستخدام للمستخدم.

ت- حالات الاستخدام الخاصة بالمراقب



رسم توضيحي 5: مخطط حالات الاستخدام للمراقب.

ج. حالات الاستخدام الخاصة بمدير النظام



رسم توضيحي 6: مخطط حالات الاستخدام لمدير النظام.

4.1- السرد النصي لحالات الاستخدام

نوضح هنا السرد النصي لحالات الاستخدام الرئيسية وهما، إدارة مناطق الاهتمام، استعراض الأحداث.

أ. حالة الاستخدام استعراض الأحداث

اسم حالة الاستخدام: استعراض الأحداث	
المستخدم المسجل	الفاعلون الأوليون
• المستخدم مسجل بالنظام، ومعروف لدى النظام، أي تم تنفيذ حالة الاستخدام "تسجيل الدخول" بنجاح.	الشروط المسبقة
• لا يوجد.	الشروط اللاحقة
يقوم المستخدم المسجل باستعراض الأحداث على الخريطة أو بشكل قائمة، والاطلاع على ملخصها، واختيار أحدها والاطلاع عليه بشكل مفصل.	الوصف

سير الأحداث

السيناريو الرئيسي الناجح – Main Success scenario

جدول 4: السيناريو الناجح لحالة الاستخدام استعراض الأحداث

النظام	المستخدم المسجل
1. يقوم المستخدم ببدء عملية الاستعراض	
2. يعيد قائمة بأنماط العرض الممكنة (خريطة، قائمة).	
3. يختار نمط العرض المراد.	
4. يعيد مجموعة الأحداث اليومية وفق النمط المختار.	
5. يستعرض الأحداث، وبعد ذلك ينهي عملية الاستعراض	

المسارات البديلة

A1: في المرحلة رقم 5، إذا أراد المستخدم استعراض حدث ما بشكل تفصيلي فيتابع كما يلي ويكمل من المرحلة رقم 5:

1. يختار الحدث الذي يريده، ويرسل معرفه	
2. يرسل معلومات الحدث (ملخص، عنوان، ...)	

المسارات الخاطئة

لا يوجد.

ب. حالة الاستخدام إدارة مناطق الاهتمام

اسم حالة الاستخدام: إدارة مناطق الاهتمام	
المستخدم المسجل	الفاعلون الأوليون
• المستخدم مسجل بالنظام، ومعروف لدى النظام، أي تم تنفيذ حالة الاستخدام "تسجيل الدخول" بنجاح.	الشروط المسبقة
• لا يوجد.	الشروط اللاحقة
يقوم المستخدم المسجل باستعراض المناطق التي يهتم بتلقي اشعارات بالأحداث التي تقع بها، إضافة منطقة جديدة ، أو إزالة منطقة اهتمام.	الوصف

سير الأحداث

السيناريو الرئيسي الناجح – Main Success scenario

جدول 5: السيناريو الناجح لحالة الاستخدام إدارة مناطق الاهتمام

المستخدم المسجل	النظام
1. يقوم المستخدم ببدء عملية الاستعراض	
	2. يعيد النظام قائمة المناطق التي يهتم بها المستخدم.
3. ينهي المستخدم عملية الاستعراض.	

المسارات البديلة

A1: في المرحلة رقم 3، إذا أراد المستخدم إضافة منطقة جديدة، فيتابع كما يلي ومن ثم يكمل من المرحلة رقم 3:

1. يختار بدء عملية إضافة منطقة اهتمام	
	2. يعيد خريطة المناطق، والنطاقات الممكنة.
3. يختار المنطقة (الإحداثيات، ونصف القطر)	
	4. يضيف النظام المنطق الجديدة إلى قائمة المناطق.
5. ينهي عملية إضافة المنطقة.	

A1: في المرحلة رقم 3، إذا أراد المستخدم إزالة منطقة جديدة، فيتابع كما يلي ومن ثم يكمل من المرحلة رقم 3:


1. يختار بدء عملية إزالة منطقة اهتمام	
	2. يعيد قائمة المناطق المهتم بها
3. يختار المنطقة التي يريد إزالتها	
	4. يزيل النظام المنطقة من قائمة المناطق.
5. ينهي عملية الإزالة المنطقة.	

المسارات الخاطئة

لا يوجد.

4.1- مخطط المكونات


يساعد المخطط أدناه في فهم مكونات النظام، حيث يتكون من عدة مكونات، وهي مكونان من أجل سحب البيانات الأول يقوم بسحب البيانات من خلال الاستقصاء النشط لـ API المقدمة من وسائل التواصل (تويتر وتيلغرام) والثاني يقوم بسحبها من خلال تقليد سلوك مستخدم حقيقي، ومن ثم يقدمان دفق البيانات للمكون التالي الذي يقوم بتطبيق المعالجات المسبقة على دفق الرسائل ومن ثم يأتي دور المكون الثالث الذي يقوم بفلتر الدفق بالاستعانة بالمصنف المدرب على التعرف على الرسائل ذات الصلة، ويمررها بدوره لمكون كشف الأحداث، الذي يصنفها إلى عناقيد ويمررها إلى المكون الأخير الذي يقوم بمعالجة لاحقة عليها. وهذا يوضح مكونات النظام بشكل عام ومجرد بعيداً عن التفاصيل التقنية.



الشكل 8: مخطط مكونات النظام.

4.1- العلاقات بين الفاعلين

يوضح المخطط أدناه العلاقات بين الفاعلين في هذا النظام.



رسم توضيحي 7: العلاقات بين الفاعلين.


الفصل الخامس

المنهجية المقترحة

يعرض هذا الفصل منهجية العمل المقترحة لتحقيق النظام بناءً على المنهجيات التي عرضناها في الفصل الثاني.

1.1- مقدمة

بعد الاطلاع على الأبحاث في مجال كشف الأحداث من وسائل التواصل الاجتماعي، تم اتخاذ المنهجية التي سنورد شرحها أدناه، حيث اعتمدنا على مقارنة معتمدة على المستند (Document Pivot Approach)، ولم نلجأ إلى العائلة الأخرى، لأن ذلك النمط من المقاربات لن يكشف الأحداث الجديدة بالذكر غير ذات الأثر الكبير. وبالإضافة على ذلك وبعد اطلاعنا على تلك الأبحاث وجدنا أنّ معظم الأبحاث قد لجأت إلى استخدام مجموعة بيانات خاصة بها، وأنّه لا يوجد مجموعة باللغة العربية تدعم مسألتنا، حيث أن المجموعة الوحيدة المتوفرة باللغة العربية كانت 7 KAWARITH وهي تضم فقط سبعة أحداث ذات أثر كبير (كزلزال سورية 2023)، لذلك هي غير مناسبة، وبالإضافة إلى ذلك كان لابد من استخدام بيانات عربية لضبط معاملات النماذج والخوارزميات المستخدمة، لذلك قمنا بجمع مجموعة البيانات الخاصة بنا واستخدامها. كما اعتمدنا على فصل منهجية سحب البيانات عن منهجية كشف الأحداث مما ساعد على جعل قناة دفع الأحداث أقل ضجيجاً (30%) من التغريدات فقط غير ذي صلة). ويوضح الشكل أدناه البنية العامة للمنهجية التي سنعمل بها.




الشكل 9: البنية العامة للمنهجية.

حيث تتكون منهجيتنا من خمسة وحدات، (1) وحدة البحث واستخراج دفع المعطيات، (2) وحدة فلترة دفع الرسائل، (3) وحدة الكشف، (4) وحدة التلخيص، (5) وحدة الاستدلال على الموقع.

وحدة البحث واستخراج دفق الرسائل

مسؤولية هذا الجزء، هو استخراج دفق الرسائل، من خلال الاستفادة من مصادر البيانات (كلمات مفتاحية، أسماء مستخدمين، قنوات، ...)، وإرسالهم إلى خدمة سحب البيانات، التي نستفيد من نتيجتها في تغذية مصادر البيانات (Feedbacks)، من أجل تعزيز دقة الرسائل، كما هو موضح بالشكل أدناه.



الشكل 10: منهجية البحث واستخراج الرسائل

تبدأ العملية بأخذ قائمة من الكلمات المفتاحية العامة (مثل، سوريا، دمشق، حادثة مروعة، ...)، وإرسالها إلى خدمة سحب البيانات التي بدورها تسحب البيانات وترسلها إلى المرحلة التالية وهي مرحلة الكشف وفي نفس الوقت تعيد إلى خدمة ال Scraping Manager قائمة بأكثر K كيان مسمى مكرر في نتائج البحث (مثل، مشفى ابن النفيس، قرية بلابلابلا، الشابة فلانة، ...) التي بدورها تستفيد منهم لتغذية مصادر البحث وتوليد كلمات مفتاحية جديدة وإرسالها من جديد للبحث عنها. حيث بهذا الشكل نكون قد غدينا مصادر البيانات بمصادر رائجة حالياً (بناءً على فرضية أنه عند وقوع حادث في قرية أو مكان ما فإن اسمه سيرد بشكل أكثر من بقية الكيانات المسماة).

وحدة فلترة دفق الرسائل

مسؤولية هذا الجزء هو فلترة الرسائل وإزالة الرسائل غير المرغوب بها (مثل الإعلانات والمنشورات الشخصية غير ذات الصلة بالمسألة)، وفي هذا الجزء اعتمدنا على بناء مصنف ثنائي، باستخدام المجموعة المنمطة التي جمعناها، حيث لجأنا لبناء هذا المصنف إلى نماذج تعلم الآلة التقليدية مثل (SVM, KNN, ...) لكون مجموعة البيانات غير كافية لاستخدام نماذج كبيرة ومن أجل بناء مصنف صغير بحيث يتم دمج مع خدمة سحب البيانات لنحصل على وكيل سحب بيانات ذكي (Scraping Agent).

وحدة كشف الأحداث


مهمة هذا المكون هو عنقدة الرسائل (التغريدات)، بحيث تجمع الرسائل التي تناقش (تقدم معلومات) عن أمر ما، ضمن عناقيد بحيث يعبر العنقود عن حدث ما، في هذه الجزئية وبعد اطلاعنا على الأبحاث الأخرى، تبين لنا أنَّ المشكلة التي تكمن في هذه الجزئية هي بتمثيل الرسائل بأشعة تحمل معلومات تمييزية (Discriminative Representation)، وبعد ذلك يتم عنقدة الرسائل باستخدام خوارزمية عنقدة تزايدية.

ومن أجل العنقدة التزايدية يوجد خوارزميتين مستخدمتان في الأبحاث التي تم الاطلاع عليها وهما SinglePass وتم استخدامها في الأبحاث (Abagissa et al., 2024; Alsaedi & Burnap, 2015; Guo et al., 2024; Ray et al., 2024)، و DBSCAN التي تم استخدامها في الأبحاث (Y. Cao et al., 2021; Ren et al., 2022; Yu et al., 2024).


ومن أجل طرائق التمثيل المستخدمة فإنَّ الطرائق المتبعة هي Word2Vec, LDA(Latent Dirichlit Allocation) , BERT, SBERT ,

في هذه الوحدة، إن أفضل نموذج حصلنا عليه هو كما يلي:

أخذ تمثيل البيان Graph Level Embedding وتمثيل العقدة Node Level Embedding مع تمثيل mBert(256) ومن ثم تطبيق خوارزمية تقليل الأبعاد PCA إلى 128 بعداً. كما هو موضح أدناه.



استبدال عملية التدريب المستمر قبل كل كتلة بيانات بعملية صيانة دورية (تدريب كل X يوم على التوازي).



وحدة تلخيص الحدث

مهمة هذا المكون هو تلخيص مجموعة الرسائل وإعطاء ملخص للحدث، وفي هذا الجزء اعتمدنا على نموذج لغة ضخمة لتلخيص الرسائل، كما بالإضافة إلى ذلك ولأنه قد يكون هنالك عدد كبير من التغريدات ضمن الحدث الواحد لذلك ليس من المنطقي أن نمررها كلها سوية، لأن ذلك غير ممكن بسبب محدودية طول الأمر Prompt المرسل إليه، ولأنها قد تحوي على معلومات مكررة، لذلك لجأنا إلى أخذ طول التغريدة، مدى الاهتمام بها (التفاعلات)، المفردات الجديدة المستخدمة، التشابه مع تغريدات في نفس الحدث، لتعريف تابع ترتيب للتغريدات ضمن الحدث، من أجل أخذ أفضل K تغريدة حسب سعة نموذج اللغة الضخم.

وحدة الاستدلال على الموقع

مهمة هذا المكون هو أخذ مجموعة التغريدات ضمن الحدث والاستدلال على الموقع المذكور فيها وإعادة إحداثياته الجغرافية، وفي هذا الجزء اعتمدنا على مجموعة البيانات IDRIS (Suwaileh et al., 2023)، من أجل تدريب ووضع تقييم لجودة النموذج، حيث تم استخدام نموذج تعرف على الكيانات المسماة، وضبطه على مجموعة البيانات، ومن ثم تعريف مجموعة من التقديرات، لتحديد الموقع المذكور انطلاقاً من أسماء المواقع المذكورة.

الفصل السادس

تصميم النظام

يوضح هذا الفصل تصميم خدمات النظام والأنماط التصميمية المرتبطة بها.


1.1- مقدمة

تم اعتماد بنية الخدمات المصغرة (micro-services) لبناء النظام، حيث يتكون انظام من مجموعة من الخدمات التي تعمل مع بعضها بشك متكامل، وتم اعتماد هذه البنية بسبب الحاجة لتطبيق قابل للتوسع بسهولة وقادر على العمل مع دق كبير من المعطيات ومعالجتها، ولأننا وبعد تحليلنا للنظام في الفصل الثالث وبعد دراستنا المرجعية في الفصل الثاني تبين لنا أن النظام قادر على التعامل مع المعطيات بشكل متوازٍ وقابل للفصل بين مكوناته بسهولة بحيث لا يوجد تتداخل فيما بينها، وأيضاً أنه يتعامل مع معطيات كبيرة فهو إذن بحاجة للتوسع أفقياً. لذلك اخترنا تلك البنية فهي تقدم الفوائد التالية:

- ♣ التوسع المستقل: يمكن توسيع كل خدمة مصغرة بشكل مستقل بناءً على الطلب، حيث تسمح هذه المرونة باستخدام الموارد بكفاءة، إذ يتم توسيع أجزاء التطبيق التي تحتاج إلى المزيد من الموارد فقط، بدلاً من النظام كله.
- ♣ المرونة في استخدام التقنيات: يمكن استخدام لغات البرمجة وأطر العمل وقواعد البيانات والتقنيات المختلفة للخدمات المختلفة، وتحسين كل خدمة بناءً على متطلباتها المحددة.
- ♣ النشر المستقل: يمكن نشر الخدمات المصغرة بشكل مستقل، مما يسمح بالتكامل المستمر والتسليم المستمر (CI/CD) مما يعطي إمكانية إصدار التحديثات وإصلاح الأخطاء على حدة.

ويوضح الشكل أدناه المخطط التصميم للنظام حيث نعرض فيه الخدمات وهي، خدمة تجريف (كشط) البيانات والتي تقوم بسحب البيانات بناءً على المهمات التي تردها من خدمة إدارة عمليات التجريف، ومن ثم تقوم بنشر البيانات المسحوبة (عبر رتل تراسل) إلى خدمة كشف الأحداث المرتبطة بمجالها، والتي بدورها تتواصل مع خدمة الاستدلال على الموقع مع نموذج لغة كبير (من أجل تعيين الموقع، وإعطاء ملخص للحدث) ومن ثم ترسل الأحداث المكتشفة إلى خدمة الأحداث التي بدورها تتولى عملية إدارة الأحداث وتفضيلات المستخدمين والإشعارات. كما ويوجد خدمة الهوية التي تتولى عملية إدارة المستخدمين والصلاحيات، وأيضاً خدمة طرفية API (API Gateway) التي تجعل المستخدم النهائي يتعامل مع النظام كما لو أن قطعة واحدة. وفي النهاية يتفاعل العميل مع خدمة الواجهات ويرسل الطلبات إلى طرفية النظام.

3.1- مخطط خدمات النظام التصميمي



الشكل 11: مخطط خدمات النظام التصميمي.

حيث يشير السهم المنقط إلى أن التواصل يكون عبر رتل تراسل (يمكن أن يكون Kafka Queue أو Rabbit MQ). ويشير الصندوق المخطط الحواف، إلى أن هذه الخدمة تعمل بشكل موزع (أي على سبيل المثال تكون كل نسخة من خدمة كشف الأحداث مرتبطة مع مجال معين أي مثلاً خدمة كشف أحداث مرتبطة مع مجال "أخبار محلية ضمن دمشق"). وبالنسبة لخدمة المجرف وخدمة إدارة عمليات السحب فهما على النمط السيد-العبد (master-slave) حيث تتولى خدمة إدارة عمليات النظام مهمة إرسال الأعمال إلى خدمات التجريف وهم بدورهم العمال. ويشير السهم المتصل إلى أن التراسل يكون عبر طلبات-ردود مباشرة متزامنة.


2.1- تصميم خدمات النظام

نعرض فيما يلي تصميمنا المقترح لخدمات النظام كل على حدة.

(1) خدمة التجريف (Scraping Service (Scraping Agent)

تقوم هذه الخدمة بسحب المهمات (وهي قائمة من مصادر البيانات المرتبطة بمجال معين ومنصة تواصل محددة) من رتل التراسل، وتقوم بتنفيذها كما يلي:


تقوم بتحميل عميل التجريف Scraping Agent الموافق لمنصة التواصل التي تتبع لها المهمة، ومن ثم يبدأ بسحب البيانات. عندما يسحب دفعة من البيانات، ترسل إلى خط أنابيب المعالجة المسبقة ومن ثم إلى خط أنابيب النشر (Pre Processing Pipeline & Publishing Pipelin). ويوضح الشكل أدناه تلك العملية.



الشكل 12: مراحل العمل ضمن خدمة تجريف البيانات.

وفي هذه الخدمة يتم استخدام النمطين التصميميين Pipes and Filters و Strategy Pattern.


ويوضح الشكل أدناه مخطط الصفوف للخدمة.




الشكل 13: مخطط الصفوف للخدمة تجريف البيانات.

(2) خدمة كشف الأحداث Event Detection Service

تقوم هذه الخدمة بقراءة دفعات الرسائل messages batches من رتل التراسل، وتقوم باستخدام خوارزمية كشف الأحداث، بكشف الأحداث الجديدة وتعديل الأحداث القديمة (في حال أتت رسائل جديدة لها)، ومن ثم كلما اكتشفت دفعة أحداث، تقوم بتنفيذ خط أنابيب المعالجة اللاحقة، حيث تقوم بتعيين موقع الحدث من خلال التواصل مع خدمة الاستدلال على الموقع، ومن ثم كتابة ملخص الحدث بالاستعانة بنموذج لغة ضخمة، إلخ. وبعد ذلك ترسل الحدث ورسائله إلى خدمة الأحداث. كما أن هذه الخدمة تعمل بشكل موزع حيث تكون مرتبطة بمجال معين تقرأ رسائله من رتل تراسل خاص به. ويوضح الشكل أدناه مخطط مكونات هذه الخدمة.




ويوضح الشكل أدناه مخطط الصفوف لها.




وعند معاينة هيكلية تلك الخدمتين، نكون قد حققنا النمط Vertical Slice Architecture، أي تقسيم النظام عمودياً إلى خدمات مختلفة مستقلة عن بعضها البعض (فصل المكونات والتداخل بين ملفاتها) ومتشابهة بمعمارياتها الداخلية أي لكلا الخدمتين نفس البيئة المعمارية.

كما ويوضح الشكل أدناه طريقة التواصل وتوزيع خدمات الكشف وتحريف البيانات، حيث وكما نرى لكل مجال، ما عدد من نسخ خدمات تحريف البيانات التي ترتبط بهذا المجال وتقوم بسحب البيانات ووضعها في رتل التراسل الخاص بهذا المجال، ومن ثم تقوم نسخة خدمة الكشف المرتبطة بهذا المجال بأخذ البيانات ومعالجتها. كما هو موضح أدناه.



3) خدمة إدارة عمليات السحب Scraping Management Service

هذه الخدمة مسؤولة عن توليد المهمات وجدولتها، وإرسالها إلى رتل التراسل مع العمال، الذين بدورهم وعند انتهائهم من مهمة ما، يقومون بسحب مهمات أخرى من رتل التراسل وكذا دواليك. ويوضح الشكل أدناه مخطط مبسط للعلاقات ما بين الكيانات ERD في هذه الخدمة.




حيث وكما نرى فإنّ لكل مجال بيانات (أخبار سياسية سورية، أخبار رياضية، أحداث محلية ضمن مدينة) مرتبط مع عدد من مجرّي البيانات، الذين يستلمون المهمات. وكل مجال أيضاً مرتبط بمجموعة من مصادر البيانات (كلمات مفتاحية، معرفات قنوات، ... إلخ)، ومصدر البيانات مرتبط مع منصة تواصل اجتماعي ما. ولكل منصة تواصل معلومات لتسجيل الدخول Credential. ولكل مجرف عدد من المهمات.

(لم أنتهي بعد من تصميم الخدمة)

4) خدمة إدارة الأحداث Events Service

تتولى هذه الخدمة عملية إدارة الأحداث (يتخاطب معها العميل للحصول على معلومات الحدث، وتتخاطب معها خدمة كشف الأحداث لتسجيل الأحداث) حيث تدير عمليات إرسال الإشعارات وإدارة مناطق اهتمام المستخدمين، والمواضيع. ويوضح الشكل أدناه مخطط العلاقات بين الكيانات ERD لهذه الخدمة.



حيث وكما نرى، فإن للحدث موضوع (سياسي، رياضي، أزمة، حوادث، ... إلخ)، وموقع (إحداثيات)، ومنطقة حدث بها. كما وله عدة رسائل تتحدث عنه وهذه الرسائل تتبع لمنصة تواصل ما. وأيضاً فإن المستخدم يبدى اهتمامه بعدة مناطق. (لم أنتهي بعد من تصميم الخدمة).

5) خدمة الاستدلال على الموقع Location Inference Service

مهمة هذه الخدمة هي استقبال طلبات الاستدلال على الموقع وهي إما رسالة نرغب في معرفة الموقع المذكور بها أو حدث (مجموعة رسائل) نرغب بمعرفة موقعه، أو عنوان (اسم الموقع) نرغب بتحديد إحداثياته. في هذه الخدمة نحتاج إلى النمط التصميمي Strategy، لتعريف أنماط التعرف على الموقع المختلفة (باستخدام نموذج لغة ضخمة أو أدوات NER). وقد تتواصل هذه الخدمة مع نموذج لغة ضخمة (حسب طريقة الاستدلال).

6) Identity Service خدمة الهوية

تتولى هذه الخدمة مهمة إدارة المستخدمين وصلاحياتهم وأدوارهم.

7) Gateway Service خدمة البوابة

بعد النظر إلى الخدمات التي تكون النظام الكلي، نجد أنّ تواصل النظام مع كل خدمة على حدة له مجموعة من المشاكل مثل عدم وجود واجهة موحدة تمثل النظام يستطيع المستخدم التخابط معها والتعامل مع النظام ككتلة واحدة، فلذلك ظهرت الحاجة لوجود مخدم يعمل كواجهة تخاطبية للنظام ويوجه الطلبات للخدمات الداخلية حسب الطلب.

8) Frontend Service خدمة الواجهة الأمامية

هذه الخدمة مسؤولة عن التفاعل والتعامل مع المستخدم، تم اعتماد معمارية الشرائح العمودية، بحيث يتم تقسيم هذه الخدمة إلى مجموعة وحدات **modules**، كل وحدة تقابل خدمة في طرف المخدم وتقوم بعرض واجهاتها، وبحيث لكل الوحدات نفس البنية المعمارية.

الفصل السابع

الأدوات المستخدمة

نعرض في هذا الفصل الأدوات وأطر العمل المستخدمة في تنفيذ النظام.

Docker -1.1

هي منصة مفتوحة مصممة لأتمتة عملية نشر التطبيقات وتوسيع نطاقها، وإدارتها في حاويات خفيفة الوزن. الحاوية هي بيئة معزولة تجمع بين التطبيق وجميع تبعياته، مما يسمح بتشغيله بشكل متسق عبر بيئات حوسبة مختلفة، مثل أنظمة تشغيل مختلفة أو مزودي الخدمات السحابية.

ASP.Net Web API -2.1

هو إطار عمل طورته شركة Microsoft يتيح إنشاء خدمات تعتمد على http. يمكن استخدام هذه الخدمات بواسطة مجموعة متنوعة من عملاء، بما في ذلك متصفحات الويب وتطبيقات الأجهزة المحمولة وخدمات الويب الأخرى. إنه جزء من إطار عمل ASP.Net. وهو مصمم خصيصاً لإنشاء واجهات برمجة التطبيقات RestFull API.

الفصل الثامن

التجارب ومقارنة النماذج

نعرض في هذا الفصل التجارب التي قمنا بها، والنماذج المقترحة وتقييمها وضبطها.

1.1- مجموعة البيانات


تم جمع مجموعة البيانات من منصة تويتر عبر البحث بكلمات مفتاحية عامة وخاصة (مثل، سوريا، دمشق، اعتصام الميدان، ...)، من تاريخ 1 أيار ولغاية 31 أيار 2025، ومن خلالها جمعنا مجموعة بيانات حجمها 20 ألف تغريدة (23 ألف قبل إزالة التكرارات) بالإضافة على معلوماتها metadata. سمينها (SAS (Golden)، وبعد ذلك قمنا بتنميط مجموعة جزئية منها يدوياً بحجم 4500 تغريدة إلى ذات صلة وغير ذات صلة (Relevant, Un Relevant)، وتم ذلك وفق دليل التنميط المبين في الملحق ب (اضغط هنا) سمينها (SAS (Labeled).

بعد ذلك تم النظر إلى الجزء من مجموعة البيانات الذي تم جمعه من خلال البحث بكلمات مفتاحية خاصة (أحداث وقعت في شهر أيار، مثل، اعتصام في مكان فلاي، رفع العقوبات الأميركية، حادث في مكان فلاي، ...)، وحجمه هو عبارة عن 6998 تغريدة بعد إزالة التكرارات، تنتمي إلى 109 أحداث وقعت في شهر أيار، تم وضع كل تغريدات ناتجة عن بحث معين في ملف منفصل (مبوبة)، وحيث بعد النظر إلى تلك النتائج (المبوبة ضمن ملف لكل حدث) كانت نسبة أكثر من 98% من التغريدات منتمية لذلك الحدث، وبالتالي كان باستطاعتنا استخدام المقاييس (ARI، AMI، NMI) المبينة في فصل الدراسة المرجعية لتقييم جودة نموذج كشف الحدث. وتمت تسمية هذا الجزء من المجموعة ب (SAS (Silver). ويوضح الجدول أدناه مثلاً على تغريدات من نفس الحدث.

جدول 6: مثال على تغريدات ضمن حدث ما.


Author	Type	Tweet Text	Tweet ID
Grok	Reply	رامز الخياط هو رجل أعمال قطري، الرئيس التنفيذي لشركة أورباكون القابضة، وهي جزء من مجموعة باور إنترناشيونال القابضة التي يملكها ويديرها عائلة الخياط في قطر. تأسست أورباكون عام 2011، وتتخصص في مشاريع الطاقة والبنية التحتية. الخ	19281218
الإخبارية السورية	Tweet	مؤتمر صحفي مشترك لوزير الطاقة محمد البشير والرئيس التنفيذي لشركة أورباكون رامز الخياط على هامش توقيع الاتفاقيات الاقتصادية مع شركات الطاقة #سوريا_نحو_الريادة_الإخبارية_السورية	92811483
شبكة أخبار سوريا	Tweet	مؤتمر صحفي لوزير الطاقة المهندس محمد البشير والرئيس التنفيذي لشركة أورباكون القابضة رامز الخياط في قصر الشعب بعد توقيع مذكرات تفاهم مع شركات دولية في مجال الطاقة.	19281069
ssy	Tweet	الرئيس التنفيذي لشركة أورباكون القابضة رامز الخياط: - ما يتم إبرامه اليوم هو بداية مشروع وطني باستثمار أجنبي قيمته 7 مليار دولار - المشروع سيؤمن الاكتفاء الذاتي من الطاقة الكهربائية في سوريا - المشروع يتضمن تطوير 4 محطات إنتاجية باستخدام أحدث ما توصلت إليه التكنولوجيا الأميركية	19281044
ssy	Tweet	أعجبنى برتوكول توقيع الاتفاقيات	19281013
ABO_OBIDA	Tweet	الرئيس التنفيذي لشركة أورباكون القابضة رامز الخياط: 🔗الاتفاقيات التي تم توقيعها اليوم ستحول سوريا من دولة لديها عجز في مجال الطاقة إلى دولة مصدرة لها	19280948

ويوضح الشكل أدناه توزيع التغريدات طوال شهر أيار، حيث يلاحظ استقرار في عدد التغريدات، باستثناء عدد قليل من الأيام التي يحدث فيها أمور مهمة (كيوم رفع العقوبات، أو أثناء الكوارث أو النزاعات المسلحة).



الشكل 14: توزيع التغريدات خلال فترة السحب.

ويوضح الشكل أدناه تواتر التغريدات خلال ساعات اليوم، حيث نلاحظ أن معظم التغريدات تكون في فترة المساء (0 - 3)، بينما ينخفض تواترها صباحاً، ويكون مسقراً ظهراً، ويفسر سبب ارتفاعها ليلاً لوجود عدة أحداث مهمة وقعت ليلاً (مثل رفع العقوبات الأميركية)، كما أن أغلب المواطنين يبدون رأيهم عما حدث خلال اليوم ليلاً. ويساعد هذا المخطط على تحديد آلية وتوقيت سحب البيانات عند وضع النظام بالخدمة.




الشكل 15: تواتر التغريدات خلال ساعات اليوم.

ويوضح الشكل أدناه مجموعة الكلمات الأكثر تداولاً خلال فترة من أحد الأيام (8 أيار - الفترة 9AM - 12 AM).




الشكل 16: مجموعة الكلمات المتداولة خلال 8 أيار- الفترة 9AM – 12 AM.

ويوضح الشكل أدناه، توزيع طول التغريدات (بالمحرف).




الشكل 17: توزيع طول التغريدات.

ويبين الشكل أدناه المدة الزمنية للأحداث، حيث كان هنالك ثلاثة أحداث استمرت لمدة أكثر من أربعة أيام، بينما كانت معظم الأحداث مدد يوم واحد فقط، كما كان هنالك عشرة أحداث تم تداولها لمدة أقل من ساعة.



الشكل 18: المدة الزمنية للأحداث.


ويوضح الشكل أدناه عدد التغريدات ضمن الحدث، حيث كانت معظم الأحداث بين ثلاثين ومئة تغريدة، بينما كان هنالك 18 حدثاً بأقل من خمس تغريدات، وكان هنالك ثلاث أحداث بأكثر من 400 تغريدة.



الشكل 19: مجال عدد التغريدات ضمن الحدث.


ويبين الشكل أدناه توزيع لغات التغريدات حيث نلاحظ أن 97.8% بالمتة منها باللغة العربية، بينما 2.2% من بقية اللغات.

Tweet Distribution: Arabic vs Other Languages




الشكل 20: توزيع لغات التغريدات.

ويبين الشكل أدناه المصادر الأكثر نشرًا للتغريدات ضمن المجموعة، وتفيد معرفتها بتحديد الجهات والمؤسسات التي تنقل الأحداث السورية.



الشكل 21: مصادر البيانات الأكثر نشرًا للأحداث المتداولة.


ويبين الشكل أدنا تحليل خطاب الكراهية في التغريدات، ويلاحظ أن 11% بالمئة من التغريدات تحض على العنف والكراهية.



الشكل 22: تحليل خطاب الكراهية والعنف.

ويبين الشكل أدناه بيان المعلومات، لرسائل تتبع لأحداث مختلفة، ويلاحظ أن المستخدمين يلجؤون لإضافة hashtags ليست ذات صلة بالحدث ذات، مما يقل أهمية ال hashtag بل وحتى الكيانات المسماة.


Message Graph for Three Small Events (Tweet ↔ Entity / Hashtag)



الشكل 23: بيان المعلومات للرسائل تتبع لأحداث مختلفة.

2.1- تجارب تصنيف التغريدات

في هذا الجزء من المنهجية، الهدف هو تصنيف التغريدات القادمة إلى ذات صلة وغير ذات صلة. ومن أجل اختيار النموذج الأفضل، تم استخدام مجموعة البيانات المنمطة التي جمعناها (SAS(Labeled). حيث تحوي مجموعة البيانات هذه على 4500 تغريدة بعد إزالة التكرارات والتغريدات باللغات غير العربية، وتكون نسبة التغريدات ذات الصلة هي 69.2% ذات صلة، و30.8% غير ذات صلة كما هو مبين بالشكل أدناه.



في المرحلة الأولى من التجارب التي قمنا بها، تم اقتراح أربع طرائق لإضافة معلومات للرسائل قبل تضمينها ولكل منها تم استخدام أربع نماذج للتمثيل Representation.

الطرائق المقترحة، هي

- ♣ (الطريقة المرجعية Base Line) استخدام نص التغريدة وحده من أجل التمثيل.
- ♣ استخدام الكيانات المسماة لوحدها (كون الرسائل ذات الصلة تتحدث عن أحداث فمن المتوقع أن تحمل الرسائل ذات الصلة كيانات مسماة أكثر من غير ذات الصلة) لتمثيل الرسائل.
- ♣ تثقيل الكيانات المسماة بأوزان لإضافة أهمية لوجود الكيان المسمى ضمن نص التغريدة.
- ♣ استبدال الكيانات المسماة بكلمات بدل Place Holders (مثل استبدال المكان المذكور بكلمة مكان أي حادث سير في دمشق => حادث سير في مكان، صرح محمد محمد الرئيس التنفيذي لشركة الشام القابضة بأنّ => صرح شخص الرئيس التنفيذي لمؤسسة بأنّ) تفيد هذه الطريقة بتجنب أن يتعلم النموذج معلومات تتعلق بمكان معين أو شخص معين وأن تكون قدرته على التعميم أفضل.

ومن أجل نماذج التمثيل تم استخدام FastText, mBert, AraBert, TF-IDF، ولكل نموذج تمثيل تم تدريب النماذج التالية SVM, KNN, Neural Network, Logistic Regression, Naïve Bayes، وتم ضبط المتوسطات من خلال تحليل أثرها على مدى ومن ثم اختيار المجا المناسب لها، وبعد ذلك إجراء grid search مع k fold cross validation مع k=5. تم التركيز على معاملين هما F1 macro و Accuracy، لأننا نريد النموذج دقيقاً ولكن ليس على حساب استبعاد تغريدات ذات صلة، لذلك ركزنا على f1 و accuracy. وكانت النتائج وفق الجدول المبين أدناه.


#	Name	Description	Model	Results							
				Accuracy		Recall		Precision		F1 Score	
				Train	Test	Train	Test	Train	Test	Train	Test
Exp. 1	FastText	Embedding Tweets with FastText Model	Neural Network	0.84	0.82	0.90	0.89	0.86	0.86	0.81	0.77
			KNN	0.86	0.81	0.93	0.89	0.88	0.87	0.81	0.75
			SVM	0.89	<u>0.84</u>	0.95	0.90	0.91	0.89	0.86	<u>0.79</u>
			Naïve Bayes	0.73	0.76	0.85	0.88	0.78	0.81	0.67	0.68
			Logistic Regression	0.84	0.81	0.91	0.88	0.87	0.86	0.81	0.76
	AraBert	Embedding Tweets with AraBert Model	Neural Network	0.86	0.82	0.88	0.85	0.92	0.90	0.85	<u>0.79</u>
			KNN	0.85	0.81	0.86	0.82	0.91	0.91	0.83	0.78
			SVM	0.99	0.81	1.00	0.88	0.99	0.87	0.99	0.77
			Naïve Bayes	0.76	0.77	0.79	0.80	0.85	0.88	0.73	0.74
			Logistic Regression	0.87	<u>0.83</u>	0.92	0.89	0.90	0.89	0.85	0.79
	mBert	Embedding Tweets with mBert Model	Neural Network	0.93	0.80	0.93	0.82	0.97	0.89	0.92	0.76
			KNN	0.86	<u>0.84</u>	0.91	0.89	0.88	0.88	0.83	<u>0.80</u>
			SVM	0.85	0.81	0.90	0.88	0.89	0.87	0.83	0.77
			Naïve Bayes	0.74	0.71	0.78	0.70	0.83	0.87	0.71	0.68
			Logistic Regression	0.84	0.81	0.90	0.88	0.87	0.86	0.81	0.76
	TF-IDF	Embedding Tweets with TF-IDF	Neural Network	0.99	0.78	0.99	0.82	0.99	0.87	0.98	0.78
			KNN	0.84	0.81	0.88	0.83	0.89	0.90	0.82	<u>0.78</u>
			SVM	0.87	<u>0.80</u>	0.93	0.89	0.88	0.84	0.84	0.74
			Naïve Bayes	0.69	0.74	0.67	0.80	0.85	0.83	0.67	0.69
			Logistic Regression	0.89	0.79	0.93	0.87	0.90	0.84	0.87	0.73

حيث كان النموذج الأفضل للتمثيل هو mBert مع نموذج knn للتعليم، حيث كانت نتائجه ل F1 macro هي 0.80، وصحة accuracy هي 84%، يليه نموذج FastText بـ F1 macro 0.79، وصحة 84%، ويوح الشكل أدما نتائج التصنيف له. وكان الفرق بين نتائج التدريب والاختبار 3%.



Classification Report - Test Set

	precision	recall	f1-score	support
0.0	0.71	0.70	0.70	254
1.0	0.88	0.89	0.89	659
accuracy			0.84	913
macro avg	0.80	0.79	0.80	913
weighted avg	0.84	0.84	0.84	913

ويوضح الشكل أدناه مصفوفة الارتباك له.



ويوضح الشكل أدناه أثر اختيار تابع المسافة هو cosine، عوضاً عن تابع المسافة الإقليدية (الشكل على اليسار)، حيث أنه حسن نتائج.



التجربة الثانية: تثقيل شعاع الكيانات المسماة

في هذه التجربة أخذنا تثقيلاً لتمثيل الكيانات المسماة (شعاع التمثيل = شعاع التمثيل القديم + w * شعاع تمثيل الكيانات المسماة)، لم تضاف هذه التجربة قيمة مضافة للنتائج، ولكنها خففت من الفرق بين نتائج التدريب والاختبار.

وكان النتائج وفق الجداول التالية.

#	Name	Description	Model	results							
				Accuracy		Recall		Precision		F1 Score	
				Train	Test	Train	Test	Train	Test	Train	Test
Exp. 2	FastText	Embedding Tweets with Fasttext + NE Weight	Neural Network	0.83	0.80	0.92	0.90	0.84	0.83	0.79	0.74
			KNN	0.85	0.80	0.92	0.87	0.87	0.85	0.82	0.75
			SVM	0.85	0.81	0.91	0.87	0.88	0.87	0.83	0.76
			Naïve Bayes	0.73	0.76	0.86	0.88	0.77	0.81	0.66	0.68
			Logistic Regression	0.84	<u>0.81</u>	0.91	0.89	0.87	0.86	0.81	<u>0.76</u>
	AraBert	Embedding Tweets with AraBert + NE Weight	Neural Network	0.84	0.81	0.96	0.93	0.83	0.83	0.79	0.74
			KNN	0.85	0.83	0.90	0.88	0.88	0.88	0.82	0.79
			SVM	0.88	0.83	0.93	0.88	0.90	0.89	0.86	0.79
			Naïve Bayes	0.78	0.79	0.78	0.78	0.89	0.91	0.77	0.76
			Logistic Regression	0.86	0.83	0.91	0.88	0.89	0.89	0.84	<u>0.79</u>
	mBert	Embedding Tweets with mBert + NE Weight	Neural Network								
			KNN	0.83	0.79	0.86	0.82	0.89	0.88	0.81	0.75
			SVM	0.84	0.80	0.90	0.86	0.87	0.86	0.81	0.75
			Naïve Bayes	0.67	0.65	0.66	0.64	0.83	0.84	0.65	0.63
			Logistic Regression	0.85	0.80	0.90	0.87	0.88	0.86	0.82	0.75
	TF-IDF	Embedding Tweets with TF-IDF + NE Weight	Neural Network	0.85	0.75	0.91	0.83	0.88	0.82	0.82	0.68
			KNN	0.83	0.75	0.88	0.83	0.87	0.82	0.80	0.75
			SVM	0.75	0.74	1.00	0.98	0.73	0.74	0.60	0.53
			Naïve Bayes	0.65	0.55	0.49	0.44	1.00	0.88	0.65	0.55
			Logistic Regression	0.85	0.77	0.92	0.85	0.86	0.83	0.81	0.70

كان أفضل نموذج في هذه التجربة هو Arabert + NE، مع التصنيف باستخدام KNN وكانت النتائج لـ 0.79 f1 macro و صحة 83%.

التجربة الثالثة: تمثيل الكيانات المسماة فقط

في هذه التجربة قمنا بأخذ التمثيل فقط للكيانات المسماة (شعاع التمثيل = شعاع تمثيل الكيانات المسماة)، لم تحسن هذه التجربة النتائج، ولكنها أعطت نتائج قريبة مما حصلنا عليه (6%-)، مما يشير إلى أن الكيانات المسماة لوحدها تحمل معلومات مفيدة تساهم في التصنيف.

#	Name	Description	Model	Results							
				Accuracy		Recall		Precision		F1 Score	
				Train	Test	Train	Test	Train	Test	Train	Test
Exp. 3	FastText	Embedding Tweets with Fasttext Model	Neural Network								
			KNN								
			SVM								
			Naïve Bayes								
			Logistic Regression								
	AraBert	Embedding Tweets with AraBert Model	Neural Network	0.73	0.75	0.95	0.94	0.73	0.77	0.60	0.60
			KNN	0.76	<u>0.74</u>	0.90	0.89	0.78	0.78	0.69	<u>0.63</u>
			SVM	0.82	0.74	0.95	0.88	0.82	0.78	0.77	0.64
			Naïve Bayes	0.64	0.65	0.67	0.69	0.78	0.80	0.61	0.61
			Logistic Regression	0.78	<u>0.73</u>	0.94	0.88	0.78	0.78	0.71	<u>0.63</u>
	mBert	Embedding Tweets with mBert Model	Neural Network	0.73	0.75	0.95	0.94	0.73	0.77	0.60	0.60
			KNN	0.75	0.73	0.90	0.88	0.77	0.78	0.68	0.62
			SVM	0.82	0.74	0.95	0.88	0.82	0.78	0.77	0.64
			Naïve Bayes	0.64	0.65	0.67	0.69	0.78	0.80	0.61	0.61
			Logistic Regression	0.78	0.73	0.94	0.88	0.78	0.78	0.78	0.73
	TF-IDF	Embedding Tweets with TF-IDF	Neural Network	0.78	0.73	0.96	0.90	0.77	0.77	0.78	0.73
			KNN	0.83	0.74	0.92	0.87	0.85	0.79	0.80	0.74
			SVM	0.78	<u>0.76</u>	0.99	0.97	0.76	0.76	0.68	0.58
			Naïve Bayes	0.67	0.62	0.56	0.53	0.93	0.91	0.67	0.61
			Logistic Regression	0.76	0.73	0.92	0.88	0.77	0.77	0.68	0.61

وكان أفضل نموذج حصلنا عليه هنا هو التمثيل باستخدام TF-IDF مع تعلم التصنيف باستخدام KNN، وكانت نتائجه هي 0.74 ل F1 macro والصحة 74%. بفارق 6%- عن أفضل نموذج حصلنا عليه.

التجربة الرابعة: استبدال الكيانات المسماة بكلمات بدل Placeholders

في هذه التجربة قمنا باستبدال الكيانات المسماة بكلمات بدل، لأننا كنا نعتقد أن النموذج يتعلم معلومات مكانية غير دقيقة لا يجب تعلمها (أي أن النموذج رأى مثلاً العبارة "وقع حادث في دمشق" بينما لم يرى العبارة "وقع حادث في حمص" لذلك كنا نعتقد أن النموذج يأخذ في الاعتبار كلمة دمشق أثناء التصنيف مما لا يجعله قادراً على التعميم لذلك قمنا باستبدالها بالعبارة "وقع حادث في مكان")، وبعد ذلك أجرينا التجارب التي يوضحها الجدول أدناه، وحصلنا على نتائج مطابقة لما حصلنا عليه في التجربة الأولى، مما يعني أن النموذج لم يكن يتعلم معلومات مكانية غير دقيقة.

#	Name	Description	Model	results							
				Accuracy		Recall		Precision		F1 Score	
				Train	Test	Train	Test	Train	Test	Train	Test
Exp. 4	FastText	Embedding Tweets with Fasttext Model	Neural Network	0.83	0.82	0.89	0.87	0.87	0.87	0.80	0.78
			KNN	0.83	0.79	0.90	0.88	0.85	0.84	0.79	0.72
			SVM	0.84	0.82	0.91	0.88	0.87	0.87	0.81	0.77
			Naïve Bayes	0.74	0.75	0.85	0.85	0.78	0.81	0.68	0.68
			Logistic Regression	0.83	<u>0.83</u>	0.90	0.89	0.85	0.87	0.80	0.78
	AraBert	Embedding Tweets with AraBert Model	Neural Network	0.87	0.82	0.91	0.88	0.90	0.88	0.85	0.78
			KNN	0.85	0.81	0.89	0.86	0.89	0.88	0.83	0.77
			SVM	0.89	0.82	0.92	0.88	0.91	0.87	0.87	0.78
			Naïve Bayes	0.76	0.77	0.79	0.80	0.85	0.88	0.73	0.74
			Logistic Regression	0.87	<u>0.83</u>	0.92	0.89	0.90	0.88	0.85	<u>0.79</u>
	mBert	Embedding Tweets with mBert Model	Neural Network	0.87	0.82	0.91	0.88	0.90	0.88	0.85	0.78
			KNN	0.85	0.81	0.89	0.86	0.89	0.88	0.83	0.77
			SVM	0.89	0.82	0.92	0.88	0.91	0.87	0.87	0.78
			Naïve Bayes	0.76	0.77	0.79	0.80	0.85	0.88	0.73	0.74
			Logistic Regression	0.87	0.83	0.92	0.89	0.90	0.88	0.85	<u>0.79</u>
	TF-IDF	Embedding Tweets with TF-IDF	Neural Network	0.96	0.81	0.98	0.88	0.97	0.86	0.96	0.76
			KNN	0.85	<u>0.83</u>	0.89	0.86	0.90	0.90	0.83	0.80
			SVM	0.84	0.82	0.89	0.88	0.88	0.87	0.81	0.77
			Naïve Bayes	0.71	0.70	0.77	0.69	0.81	0.86	0.68	0.67
			Logistic Regression	0.84	<u>0.83</u>	0.90	0.89	0.87	0.87	0.81	0.78

حيث كان أفضل نموذج حصلنا عليه في هذه التجربة هو التمثيل باستخدام TF-IDF والتصنيف باستخدام KNN، حيث كانت نتائجه هي F1 macro 0.80 وصحة 83%.

2.1- تجارب كشف الأحداث (نمذجة المواضيع)

كما سبق وذكرنا أننا في هذا الجزء من العمل، نتلخص مهمتنا بإيجاد طريقة تمثيل وعنقدة مناسبة للبيانات. في هذه الجزئية يلجأ الباحثون لتقييم نموذجهم بطريقتين الأولى بالوضع offline والثانية بالوضع online. ويعرف التقييم بوضع عدم الاتصال Offline Evaluation، بأنه التقييم الذي يجري على بيانات تاريخية، أو مجموعة مسبقاً دون الحاجة إلى تفاعل حي للمستخدم أو أخذ الزمن بعين الاعتبار (نتعامل مع كامل مجموعة البيانات دفعة واحدة) (Abagissa et al., 2024)، بينما يعرف التقييم الحي Online Evaluation، بأنه التقييم الذي يجري بشكل حي، أي بأخذ زمن وصول الرسائل بالاعتبار، حيث تصل الرسائل كتلة تلو كتلة Block By Block على التوالي M1, M2, ...

1.1.1 تقييم النماذج بنمط عدم الاتصال Offline Evaluation

هنا بدأنا بتقسيم مجموعة البيانات إلى جزئين هما مجموعة الضبط Tuning Set التي استخدمناها لضبط المعاملات الفوقية Hyper Parameters للنموذج المقترح، ومجموعة التقييم التي استخدمناها لاختبار النموذج ومقارنة النتائج. لم نأخذ مجموعة تدريب لأن العملية التي قمنا بها هي Unsupervised أي النماذج المقترحة والمستخدم لا تحتاج إلى تدريب.

وقمنا بأخذ الرسائل من أول أسبوع (من 1 أيار ولغاية 7 أيار) لمجموعة الضبط وعددها 939 رسالة تشكل 13% من مجموعة البيانات، وأخذ بقية الرسائل للتقييم وعددها 6064.

أخذنا معايير التقييم هي NMI المعلومات المتبادلة المميرة (قيمه بين 0 و 1 والأفضل هو الأعلى)، AMI المعلومات المتبادلة المضبوطة، ARI مؤشر العشوائية المضبوط، وهذه المعايير تم استخدامها في معظم الأبحاث المرجعية (Abagissa et al., 2024; Guo et al., 2024; Ray et al., 2024; Ren et al., 2022; Yang et al., 2024; Yu et al., 2024). وتم التركيز والمقارنة بين النماذج وفق المعيار NMI وهذا ما قام به الباحثون المذكورون أعلاه.

أجرينا عدداً من التجارب، حيث بدأنا باختبار النماذج المستخدمة في الأبحاث السابقة وهي LDA, Word2Vec, WMD, Bert, sBert, FastText.

من أجل Bert، استخدمه الباحثون من خلال أخذ متوسط التضمينات (أي ليس ك Sentence Transformer) وقمنا باستخدام النسخة العربية منه AraBert.

ومن أجل sBert، أي استخدام Bert ك Sentence Transformer قمنا باستخدام النسخة العربية منه وهي mBert.

من أجل FastText لم يستخدمه الباحثون في الأوراق السابقة، ونحن استخدمناه لأنه يعالج مشكلة Out of Vocabulary وهو يعطي تضمين أفضل للكلمة (مع وجود أخطاء إملائية) كونه يستخدم n-gram على مستوى الحروف.

من أجل WMD، أخذ معه FastText كنموذج تضمين.


في التجربة الأولى أخذنا النماذج السابقة مع خوارزمية العنقدة DBSCAN.

بدأنا من أجل كل نموذج من النماذج السابقة بتحليل أثر كل معامل على حدى، والمعاملات لهذه النماذج هي بعد شعاع التضمين، العدد الأصغري للعناصر min Samples، معامل المسافة epsilon. وكانت أنماط النتائج متشابهة بين النماذج.


قمنا من أجل كل معامل بعمل K Cross Validation أثناء البحث عن المعامل الأفضل وأخذنا $k=5$.

- تحليل معامل المسافة min epsilon


تختلف قيم هذا المعامل حسب طريقة التضمين، ولكن بمعظم التجارب كانت بين 0.1 و 0.6، يوضح الشكل أدناه أثر هذا المعامل على نتائج العنقدة، حيث يبين من أجل كل قم له، متوسط نتائج ال cross validation مع الانحراف المعياري، من أجل طريقة التمثيل mBert، (بقية الطرائق كانت النتائج متشابهة كشكل التابع مع تغير قيمة eps الأفضل)، حيث نلاحظ أنه من أجل القيم الصغيرة ل eps، >0.23 ، كان الانحراف المعياري كبيراً، عى عكس بقية القيم.




الشكل 24: أثر المعامل eps على النتائج باستخدام mBert لتمثيل الرسائل.




- تحليل معامل الكثافة min Samples، قيم هذا المعامل كانت في معظم الحالات بين 3 و 7، القيم الكبيرة كانت تؤدي إلى نتائج غير جيدة، بسبب وجود عدد من الأحداث بعدد قليل من الرسائل، كان الانحراف المعياري ما يقارب ± 0.4 ، ويشكل تقريباً نسبة $\pm 8\%$ ، مما يوحي بوجود overfitting، لذلك في التجارب القادمة سنلجأ إلى تعزيز مجموعة البيانات.



- تحليل أثر الأبعاد، يوضح الشكل أدناه أثر بعد فضاء التضمين على النتائج.



يوضح الشكل أدناه مقارنة بين النتائج التي حصلنا عليها، حيث كان أفضلها هو mBert حيث كان تحسينه عن النموذج الذي يليه هو 45%.



ويوضح الجدول أدناه بقية المقاييس.

#	Approach	Description	Embedding Model	Results		
				NMI	AMI	ARI
Exp. 1	AraBert	DBSCAN + Arabert	AraBert 768	0.1765	0.0882	0.0039
			AraBert 320	0.1983	0.1030	0.0046
			AraBert 128	0.2278	0.1259	0.0059
			AraBert 32	<u>0.2734</u>	<u>0.1881</u>	<u>0.0104</u>
Exp. 2	mBert	DBSCAN +mBert	mBert 768	0.5056	0.4158	0.0295
			mBert 512	0.5066	0.4165	0.0297
			mBert 256	<u>0.5085</u>	<u>0.4182</u>	<u>0.0302</u>
			mBert 128	0.5060	0.4247	0.0346
			mBert 64	0.4790	0.4217	0.0518
			mBert 32	0.0578	0.0347	0.0025
Exp. 3	FastText	DBSCAN +FastText	FastText 300	0.3213	0.1972	0.0091
			FastText 160	0.3464	0.2223	0.0095
			FastText 128	<u>0.3583</u>	<u>0.2354</u>	<u>0.0102</u>
			FastText 64	0.3088	0.2148	0.0130
Exp. 4	Word2Vec	DBSCAN+Word2Vec	Word2Vec 300	<u>0.3361</u>	<u>0.2470</u>	<u>0.0157</u>
			Word2Vec 160	0.2079	0.1331	0.0101
			Word2Vec 128	0.1714	0.1059	0.0081
			Word2Vec 64	0.1018	0.0569	0.0054
Exp. 5	LDA	DBSCAN + LDA	Topics 140	0.2347	<u>0.1442</u>	<u>0.0106</u>
			Topics 130	<u>0.2374</u>	0.1353	0.0105
			Topics 90	0.1082	0.0506	0.0037
			Topics 50	0.0265	0.0007	0.0127

التجربة الثانية: خوارزمية العنقدة الهرمية HDBSCAN

عند استخدامنا في التجربة السابقة لخوارزمية العنقدة DBSCAN، كانت تعاني في الوضع الحي من اختلاف كثافة الأحداث مما يؤدي إلى تغير قيمة epsilon المناسبة، وبالتالي كنات النتائج سيئة كما هو موضح أدناه، لذلك لجأنا إلى خوارزمية العنقدة HDBSCAN وهي قادرة على إيجاد عناقيدة بكثافات مختلفة.


في هذه التجربة أخذنا خوارزمية العنقدة الهرمية HDBSCAN، وأخذنا كنماذج للتمثيل AraBert, mBert, Distilli, mBert, LDA, Fasttext, Word2Vec.

وإنَّ موسطات هذه الخوارزمية التي تحتاج إلى ضبط هي العدد الأصغري للعينات min samples، والحجم الأصغري للعنقود min cluster size. وتم تحليل هذه الموسطات كل على حدى كما هو مبين أدناه:

ومن أجل تحليلها تم أخذ K Fold Cross Valdiation، من أجل $k=5$ وأخذ متوسط النتائج وانحرافها المعياري.


• أثر معامل حجم العنقود الأصغري

(كانت النتائج متشابهة لمعظم التجارب كشكل المنحني مع اختلاف القيم)، من أجل قيم صغيرة نسبياً لحجم العنقود (بين 3 و6) كانت النتائج متشابهة مع انحراف معياري صغير، ومن أجل قيم متوسطة له (أصغر من 14 كانت النتائج أقل ومع انحراف معياري صغير)، ومن أجل قيم كبيرة كانت النتائج سيئة ومع انحراف معياري كبير مما يدل على وجود ضبط زائد overfitting.



• أثر معامل حجم العينات


كانت النتائج متشابهة لجميع التجارب، ولم يكن لهذا المعامل أثر كبير على النتائج، حي كانت النتائج مستقر مع اختلاف قيم هذ المعامل مع انحراف معياري أصغر للقيم الصغير (3,4)



الشكل 25: أثر معامل حجم العينات على النتائج.

- أثر عدد الأبعاد في التمثيل على النتائج

على عكس التجربة السابقة، في هذه التجربة لم يكن لعدد الأبعاد أثر كبير على النتائج.




وبعد تحليلها واختيار المجالات المناسبة للبحث في قيم المعاملات، تم ضبط هذه المعاملات من خلال البحث في تلك المجالات grid search، وكانت النتائج كما هو مبين بالجدول أدناه.

جدول 7 : نتائج التجربة الثانية.


#	Approach	Embedding Model	Results		
			NMI	AMI	ARI
Exp. 1	HDBSCAN + Arabert	AraBert 768	<u>0.3559</u>	<u>0.2408</u>	<u>0.0096</u>
		AraBert 320	0.3496	0.2349	0.0094
		AraBert 128	0.3304	0.2204	0.0094
		AraBert 64	0.3031	0.1930	0.0073
Exp. 2	HDBSCAN +mBert	mBert 768	0.4815	0.3711	0.0249
		mBert 512	<u>0.4838</u>	<u>0.3731</u>	<u>0.0251</u>
		mBert 256	0.4826	0.3715	0.0249
		mBert 128	0.4717	0.3600	0.0219
		mBert 64	0.4500	0.3347	0.0198
Exp. 3	HDBSCAN +FastText	FastText 300	<u>0.3593</u>	0.1902	0.0083
		FastText 160	0.3482	0.2008	0.0089
		FastText 128	0.3324	0.2188	0.0106
		FastText 64	0.3199	<u>0.2261</u>	<u>0.0106</u>
Exp. 4	HDBSCAN+Word2Vec	Word2Vec 300	<u>0.3522</u>	<u>0.2269</u>	<u>0.0104</u>
		Word2Vec 160	0.3295	0.2062	0.0079
		Word2Vec 128	0.3246	0.2007	0.0075
		Word2Vec 64	0.3080	0.1884	0.0068
Exp. 5	HDBSCAN+ Distilli mBert	Distilli mBert 384	<u>0.3686</u>	<u>0.2537</u>	<u>0.0116</u>
		Distilli mBert 256	0.3672	0.2536	0.0116
		Distilli mBert 128	0.3517	0.2490	0.0090
		Distilli mBert 64	0.3352	0.2138	0.0077
Exp. 5	HDBSCAN + LDA	Topics 125	<u>0.2747</u>	0.1495	0.0038
		Topics 100	0.2552	0.1184	0.0038
		Topics 75	0.2365	0.1099	0.0039
		Topics 50	0.2315	<u>0.2315</u>	<u>0.0680</u>

حيث كان النموذج الأفضل للتمثيل هو mBert بجودة NMI 0.48، بتحسين عن الذي يلي بمقدار 25%، Distilli mBert بجودة 0.36 NMI.



الشكل 26: نتائج العنقدة في التجربة الثانية.


ويوضح الشكل أدناه النتائج على مجموعة الضبط ومجموعة التقييم، حيث كانت النتائج متقاربة ولا يوجد تفاوت كبير في النتائج، وكانت النتائج على مجموعة التقييم أدق من مجموعة الضبط.



الشكل 27: الفرق بين نتائج الضبط والاختبار.


التجربة الثالثة: إضافة شعاع الكيانات المسماة

في التجربة الثانية قمنا بإضافة شعاع تمثيل الكيانات المسماة، إلى شعاع التمثيل الأصلي، وذلك بهدف جعل التمثيل يأخذ مكان الحدث والفاعلين فيه أثناء العنقدة، لتفادي مشكلة تجميع أحداث متشابهة في أماكن مختلف.



الشكل 28: مثال عن طريقة دمج شعاع تمثيل الكيانات المسماة.

في هذه التجربة أخذنا نماذج التمثيل السابقة، وتم استخدام Stanza NER، لاستخلاص الكيانات المسماة المذكورة في النص. وتم استخدام خوارزمية تقليل الأبعاد PCA، لاختزال الأبعاد لشعاع تضمين الكيانات المسماة، وتم اختيار البعد الأمثل باستخدام طريقة الـ Explainable Variance كما هو مبين في الشكل أدناه.




ويلاحظ أن عدد الأبعاد اللازم لتمثيل الكيانات المسماة أصغر بكثير من عدد الأبعاد اللازم لتمثيل الجمل. ويوضح الجدول أدناه النتائج التي حصلنا عليها.


جدول 8: نتائج التجربة الثالثة.

#	Approach	Embedding Model	Results		
			NMI	AMI	ARI
Exp. 1	HDBSCAN + Arabert	AraBert 768	<u>0.3759</u>	<u>0.2665</u>	<u>0.0160</u>
		AraBert 320	0.3591	0.2434	0.0129
		AraBert 128	0.3413	0.2340	0.0128
		AraBert 64	0.3108	0.2063	0.0104
Exp. 2	HDBSCAN +mBert	mBert 768	0.4432	0.3194	0.0169
		mBert 512	0.4431	0.3188	0.0169
		mBert 256	0.4424	0.3170	0.0165
		mBert 128	0.4400	0.3157	0.0161
		mBert 64	0.4328	0.3052	0.0147
Exp. 3	HDBSCAN +FastText	FastText 300	0.3873	0.2582	0.0146
		FastText 160	0.3780	0.2536	0.0141
		FastText 128	0.3763	0.2502	0.0138
		FastText 64	0.3634	0.2314	0.0101
Exp. 4	HDBSCAN+Word2Vec	Word2Vec 300	0.3505	0.0087	0.2154
		Word2Vec 160	0.3511	0.0075	0.2183
		Word2Vec 128	0.3500	0.0083	0.2186
		Word2Vec 64	0.3421	0.0090	0.2171
Exp. 5	HDBSCAN + Distilli mBert	Distilli mBert 384	0.3479	0.2139	0.0084
		Distilli mBert 256	0.3438	0.2092	0.0074
		Distilli mBert 128	0.3468	0.2116	0.0076
		Distilli mBert 64	0.3350	0.2006	0.0062
Exp. 5	HDBSCAN + LDA	Topics 125	0.3879	0.2513	0.0133
		Topics 100	0.3774	0.2508	0.0154
		Topics 75	0.3665	0.2253	0.0106
		Topics 50	0.3600	0.2253	0.0139

في هذه التجربة تحسن النتائج لنماذج Fasttext, Arabert, Word2Vec LDA حيث تحسنت جودة LDA من 0.26 NMI إلى 0.39 NMI، ولكن نموذج mBert لم يتحسن، وبقي هو أفضلهم.




ويوضح الشكل أدناه الفرق بين نتائج الاختبار والتقييم.




التجربة الرابعة: نموذج HCRC المرجعي


في هذه التجربة تم استخدام النموذج المرجعي HCRC، الذي يستخدم كخوارزمية عنقدة الخوارزمية SinglePass، وله مكونان يعطيان Graph Level Embedding و Node Level Embedding. وفي هذه التجربة قيمنا النموذج المرجعي على مجموعة البيانات خاصتنا، جربنا أيضاً تحليل مكونات هذا النموذج كل على حدى وإضافة مكونات أخرى. يوضح الشكل أدناه التحسين الذي قدمه هذا النموذج مقابل أفضل نموذج وثلنا إليه، حيث كان مقدار تحسينه هو 17%.




ويوضح الشكل أدناه نتائج مكونات كل جزء لوحده.



بعد ذلك تم تجريب أخذ Graph Level Embedding مع Node Level Embedding مع mBert Embedding ومن ثم تقليص الأبعاد إلى 128 باستخدام PCA وكانت النتائج هي 0.62 مقابل 0.58 للنموذج المرجعي.



ويبين المخطط أدناه مقارنة النتائج التي اختبرناها في هذه التجربة.



وبين الجول أدناه نتائج التجارب التي قمنا بها.

#	Approach	Embedding Model	Results		
			NMI	AMI	ARI
Exp. 1	SinglePass+ mBert	Graph +Node (512)	0.5885	0.4803	0.2320
		Graph +Node (128)	0.5993	0.4066	0.2409
		Graph +Node +mBert + PCA	0.6265	0.4118	0.3576
		Node level	0.5380	0.4362	0.1645
		Graph level	0.3125	0.3074	0.0428
		Graph + mBert(256)	0.5395	0.4668	0.1957
		Graph+ Node +mBer(256)	0.5488	0.4448	0.1838
Exp. 3	HDBSCAN+ AraBert	Node(128)	0.2831	0.1963	0.0067
		Graph + Arabert(128)	0.2790	0.2221	0.0093
		Node + Graph	0.3001	0.2137	0.0091
Exp. 4	HDBSCAN+ mBert	Node	0.4684	0.3612	0.0229
		Graph +mBer(256)	0.5145	0.4367	0.0327
		Graph+ Node +mBert(256)	0.4770	0.3953	0.0244
Exp. 5	HDBSCAN+ Distill Bert	Node	0.3736	0.2644	0.0131
		G + Distill Bert(128)	0.4015	0.2924	0.0149
		Graph+ Node+ Distill Bert	0.3985	0.2327	0.0102
		Graph + Node	0.3664	0.2655	0.0118

1.1.1 تقييم النماذج بنمط الحى Online Evaluation

هنا قمنا كما قام (Abagissa et al., 2024; Guo et al., 2024; Ray et al., 2024; Ren et al., 2022; Yang et al., 2024; Yu et al., 2024) بتقسيم مجموعة البيانات إلى كتل $M_0, M_1, \dots, M_{24}$ ، بحيث تحوي الكتلة الأولى M_0 الرسائل الواردة خلا الأسبوع الأول، بينما تحوي الكتل $M_1, \dots, M_{24}$ ، على الرسائل الواردة يوماً بيوم، ويوضح الشكل أدناه إحصائيات هذه الكتل.

Block	Date	Size	Events	Block	Date	Size	Events
M0	Before 8 May	934	44	M13	20-May	265	19
M1	8-May	85	10	M14	21-May	1005	20
M2	9-May	16	7	M15	22-May	231	14
M3	10-May	81	8	M16	23-May	417	14
M4	11-May	33	8	M17	24-May	394	15
M5	12-May	294	10	M18	25-May	384	19
M6	13-May	211	8	M19	26-May	387	8
M7	14-May	287	8	M20	27-May	209	9
M8	15-May	127	10	M21	28-May	225	8
M9	16-May	47	9	M22	29-May	277	14
M10	17-May	171	12	M23	30-May	352	11
M11	18-May	164	12	M24	31-May	165	4
M12	19-May	180	16				

جدول 9: إحصائيات كتل الرسائل.

بحيث يتم تمرير الكتل، كتلة تلو أخرى إلى النموذج المقترح، ليقوم بعنقدها، ومن الجدير بالذكر هنا، أنه يجب تعديل خوارزمية العنقدة بحيث تقوم بإهمال الرسائل القديمة (التي يتجاوز قدمها X يوم، وأن تأخذ معامل آخر وهو حجم النافذة W (نافذة منزلة) لمراعاة عدم أخذ كمية ضخمة من الرسائل التي تؤثر على أداء النموذج.


وأخذنا معايير التقييم هي NMI المعلومات المتبادلة المميرة لمقارنة النماذج وتقييمها، كما قمنا بحساب المقاييس الأخرى AMI المعلومات المتبادلة المضبوطة، ARI مؤشر العشوائية المضبوط، وأرفقناه بالملحق، وهذه المعايير تم استخدامها في معظم الأبحاث المرجعية (المذكورون سابقاً). وأجرينا عدداً من التجارب، حيث بدأنا باختبار النماذج المستخدمة في الأبحاث السابقة وهي LDA, Word2Vec, WMD, Bert, sBert, FastText.

التجربة الأولى

في التجربة الأولى أخذنا النماذج السابقة مع خوارزمية العنقدة HDBSCAN، بعدما عدلناها لتعمل بشكل تزايدى، وأضافنا لها معاملين هما (1) معامل التذكر T الذي يحدد عمر الرسائل قبل إهمالها، (2) معامل حجم النافذة W ، الذي يحدد حجم الرسائل التي يتعامل معها النموذج (بحيث يتم وضع الرسائل في Buffer وإزالة الرسائل من نهايته كلما امتلاء).

من أجل هذه التجربة اختبرنا طرائق التضمين التالية (mBert, AraBert, Word2Vec, FastText, LDA).

من أجل الـ LDA، أخذنا عدد المواضيع topics هو 60. ولاختيار عدد أبعاد بقية الطرائق، تم استخدام طريقة Explainable Variance، مع خوارزمية اختزال الأبعاد PCA. ويوضح المخطط أدناه مثالاً على ذلك.



ويوضح الجدول النتائج التي حصلنا عليها.

	M_1	M_2	M_3	M_3	M_4	M_5	M_6	M_7	M_8	M_9	M_{10}	M_{11}
mbert	0.440	0.436	0.460	0.532	0.480	0.644	0.463	0.364	0.373	<u>0.330</u>	0.576	0.544
AraBert	0.278	0.372	0.366	0.316	0.306	0.392	0.339	0.228	0.205	0.246	0.346	0.419
Word2Vec	0.356	0.374	0.379	0.349	0.271	0.405	0.363	0.087	0.163	0.189	0.356	0.330
FastText	0.278	0.372	0.366	0.316	0.306	0.392	0.339	0.228	0.205	0.246	0.346	0.419
LDA	<u>0.381</u>	<u>0.395</u>	<u>0.392</u>	<u>0.401</u>	<u>0.421</u>	0.548	0.405	0.317	0.369	0.345	<u>0.435</u>	<u>0.448</u>
	16%	10%	17%	33%	14%	18%	14%	15%	1%	-4%	32%	21%

	M_{12}	M_{13}	M_{14}	M_{15}	M_{16}	M_{17}	M_{18}	M_{19}	M_{20}	M_{21}	M_{22}	M_{23}	M_{24}
mbert	0.557	0.503	0.562	0.721	0.625	0.448	0.556	0.462	0.346	0.406	0.572	0.575	0.547
AraBert	0.431	0.332	0.352	0.420	0.415	0.354	0.407	0.351	0.266	0.401	0.551	0.478	0.404
Word2Vec	0.415	0.454	0.209	0.408	0.437	0.352	0.452	<u>0.361</u>	<u>0.315</u>	<u>0.430</u>	0.508	0.455	<u>0.438</u>
FastText	0.431	0.332	0.352	0.420	0.415	0.354	0.407	0.351	0.266	0.401	<u>0.551</u>	<u>0.478</u>	0.404
LDA	<u>0.436</u>	<u>0.466</u>	<u>0.410</u>	<u>0.540</u>	<u>0.459</u>	<u>0.395</u>	<u>0.443</u>	0.351	0.273	0.337	0.492	0.446	0.473
	28%	8%	37%	33%	36%	13%	25%	32%	26%	21%	16%	29%	16%

جدول 10: نتداج التجربة الأولى.

(الخط الغامق أعلى نتيجة، الرقم الذي تحته خط ثاني أعلى نتيجة)

في هذه التجربة، كانت طريقة التضمين mBert، هي الأفضل، حيث كانت أفضل من بقية الطرائق في 23 كتلة من أصل 24. وكانت أفضل من ثاني أفضل طريقة (LDA) بتحسين قدره 20%. ويعود ذلك كون mBert يعطي تضميناً للجملة بناءً على سياقها، بينما LDA هو طريقة إحصائية لنمذجة المواضيع، وبقية الطرائق تعتمد على أخذ متوسط تضمينات الكلمات.

وكانت من الأخطاء التي رأيناها من النمط


- تجميع الرسائل حسب معناها (أي مثلاً رسائل الحرائق تقع بالقرب من بعضها في فضاء التمثيل على الرغم من أن الحرائق تحدث في أماكن مختلفة، مما يؤدي إلى تداخل في الأحداث)
- كون العقدة تحدث على كامل المجموعة كان هناك أحداث وقعت في نفس المكان ولكن بزمانين مختلفين (العثور على مستودع*** في ريف دمشق)
- كان هنالك بعض الأحداث التي تم تجميعها وفق هدف غير فعل الحدث (كتجميع تصريحات وزير الخارجية على ثلاثة أحداث مختلفة عوضاً عن أن تكون التصريحات تنتمي إلى الحدث، مثل تصريحات الوزير على رفع العقوبات الأمريكية، تصريحاته على زيارة دولة فرنسا، تصريحاته على رفع العقوبات الأوروبية)
- وجود ضجيج (الرسائل غير ذات الصلة كانت قليلة في الحدث الواحد، ولكن عند تجميع الأحداث كانت كثيرة)

وعليه:

الأخطاء من النمط الأول والثالث من المفترض أنه بإمكاننا تفاديها وتحسين النتائج، إذا أخذنا الكلمات المكانية، والكلمات الرئيسية بطريقة التضمين.



الأخطاء من النمط الثاني، يمكننا تفاديها عند أخذ الزمن بالاعتبار.

والأخطاء من النمط الرابع هي غير قابلة للتفادي في العقدة (مما يوجب علينا إضافة مرحلة معالجة لاحقة لإزالتها).




ويوضح الشكل أعلاه مخطط قيم NMI للنماذج المستخدمة، حيث وكما ذكرنا كان mBert هو الأفضل يليه LDA. وكانت نتائج بقية النماذج متقاربة.

ويوضح الشكل أدناه معيار التقييم AMI، حيث كما نلاحظ أيضاً أنّ mBert كان الأفضل بناءً عليه.




ويوضح الشكل أدناه أثر حجم النافذة الزمنية (معامل النسيان T)، على النتائج، حيث قمنا بالاختبار من أجل القيم (2 إلى خمسة أيام) وأخذنا متوسط القيم وانحرافها المعياري وكانت النتائج متقاربة جداً، حيث يوضح الشكل أدناه المتوسط والانحراف المعياري للنتائج لقيم مختلفة لـ T، حيث كانت قيم الانحراف المعياري صغيرة جداً.




الشكل 29: أثر معامل حجم النافذة الزمنية على نتائج النموذج.

ويوضح الشكل التالي، أثر معامل حجم النافذة المنزلقة Sliding Window على النتائج، وكانت القيم الصغيرة لـ W (400-200) تؤدي إلى نتائج متفاوتة، أي في الكتل الكبيرة تكون قيم nmi صغيرة جداً بسبب نسيان الأحداث الحالية بسبب كبر جدم كتلة الرسائل، بينما القيم الكبيرة لـ W ($500 >$) كانت تؤدي إلى نتائج متقاربة فيما بينها. ويوضح الشكل أدناه المتوسط والانحراف المعياري للنتائج بعد إجراء تجارب مختلفة لقيم W .




الشكل 30: أثر معامل حجم النافذة على النتائج.

ويوضح الشكل أدناه أسقاط تمثيل الرسائل على فضاء ثنائي الأبعاد.



التجربة الثانية: إضافة شعاع الكيانات المسماة

في هذه التجربة، من أجل كل نموذج من النماذج السابقة قمنا باستخراج الكيانات المسماة المذكورة في النص وتمثيلها باستخدام النموذج، وبعد ذلك اختصار البعد باستخدام PCA ومن ثم إضافتها إلى شعاع تمثيل الجملة Concatenation.




في هذه التجارب لم نحصل على قيمة مضافة على النتائج، حيث بقي mBert أفضل من AraBert + NE بـ 25%.


	M_1	M_2	M_3	M_3	M_4	M_5	M_6	M_7	M_8	M_9	M_{10}	M_{11}
mbert +NE	0.278	0.372	0.366	0.316	0.306	0.392	0.339	0.228	0.205	0.246	0.346	0.419
AraBert +NE	0.320	0.368	0.341	0.252	0.287	<u>0.422</u>	<u>0.399</u>	<u>0.273</u>	<u>0.253</u>	<u>0.295</u>	<u>0.373</u>	<u>0.420</u>
Word2Vec +NE	0.327	0.345	0.328	<u>0.401</u>	<u>0.341</u>	0.209	0.255	0.103	0.136	0.145	0.260	0.289
FastText +NE	<u>0.403</u>	<u>0.446</u>	<u>0.440</u>	0.356	0.327	0.334	0.304	0.210	0.191	0.221	0.267	0.294
Previous	0.440	0.436	0.460	0.532	0.480	0.644	0.463	0.364	0.373	0.330	0.576	0.544
	-27%	-15%	-26%	-53%	-40%	-34%	-14%	-25%	-32%	-11%	-35%	-23%

	M_{12}	M_{13}	M_{14}	M_{15}	M_{16}	M_{17}	M_{18}	M_{19}	M_{20}	M_{21}	M_{22}	M_{23}	M_{24}
mbert +NE	0.431	0.332	0.352	0.420	0.415	0.354	0.407	<u>0.351</u>	0.266	0.401	0.551	0.478	0.404
AraBert +NE	<u>0.414</u>	<u>0.333</u>	<u>0.366</u>	<u>0.466</u>	0.397	<u>0.450</u>	<u>0.473</u>	0.342	0.212	<u>0.500</u>	<u>0.593</u>	0.449	0.454
Word2Vec +NE	0.248	0.174	0.171	0.332	0.306	0.336	0.472	0.267	<u>0.290</u>	0.460	0.529	0.506	0.346
FastText +NE	0.356	0.309	0.272	0.366	<u>0.437</u>	0.351	0.430	0.309	0.284	0.471	0.582	<u>0.549</u>	<u>0.470</u>
Previous	0.557	0.503	0.562	0.721	0.625	0.448	0.556	0.462	0.346	0.406	0.572	0.575	0.547
	-26%	-34%	-35%	-35%	-37%	0%	-15%	-26%	-39%	23%	4%	-22%	-17%

ويوضح الرسم أدناه الفارق بينهما




كما ويبين الشكل أدناه مقارنة الطرائق المتبعة في هذه التجربة مع mBert.



التجربة الثالثة: إضافة شعاع الكيانات المسماة بشكل منفصل

في هذه التجربة، من أجل كل نموذج من النماذج السابقة قمنا باستخراج الكيانات المسماة المذكورة بشكل منفصل (الأماكن المذكورة، الأشخاص، المنظمات) في النص وتمثيل كل منها بشعاع باستخدام النموذج، وبعد ذلك اختصار البعد لكل منها باستخدام PCA ومن ثم إضافتهم إلى شعاع تمثيل الجملة Concatenation، كما هو مبين بالشكل أدناه.



ولكن، وكما في التجربة السابقة، أيضاً لم نحصل على قيمة مضافة. حيث بقي نموذج mBert، ولكن كانت نتائج هذه التجربة أفضل من سابقتها حيث اقتربت النتائج من نتائج mBert التي حصلنا عليها في التجربة الأولى.


ويوضح الجدول أدناه النتائج التي حصنا عليها.

	M_1	M_2	M_3	M_3	M_4	M_5	M_6	M_7	M_8	M_9	M_{10}	M_{11}
mbert	0.351	0.557	0.575	0.469	0.374	0.497	0.450	0.305	0.290	0.311	0.420	0.456
AraBert	0.267	0.370	0.375	0.343	0.312	0.385	0.288	0.244	0.184	0.250	0.393	0.444
Word2Vec	0.336	0.348	0.340	0.397	0.333	0.409	0.260	0.096	0.126	0.135	0.254	0.276
FastText	0.385	0.426	0.400	0.349	0.314	0.335	0.312	0.205	0.165	0.194	0.265	0.281
Previous	0.440	0.436	0.460	0.532	0.480	0.644	0.463	0.364	0.373	0.330	0.576	0.544
	-20%	28%	25%	-12%	-22%	-23%	-3%	-16%	-22%	-6%	-27%	-16%


	M_{12}	M_{13}	M_{14}	M_{15}	M_{16}	M_{17}	M_{18}	M_{19}	M_{20}	M_{21}	M_{22}	M_{23}	M_{24}
mbert	0.459	0.494	0.444	0.534	0.459	0.443	0.519	0.433	0.319	0.462	0.569	0.567	0.502
AraBert	0.438	0.337	0.375	0.458	0.398	0.357	0.411	0.380	0.292	0.377	0.525	0.483	0.436
Word2Vec	0.235	0.180	0.188	0.325	0.303	0.278	0.475	0.266	0.300	0.454	0.532	0.511	0.353
FastText	0.350	0.297	0.254	0.361	0.431	0.356	0.445	0.326	0.277	0.455	0.580	0.545	0.463
Previous	0.557	0.503	0.562	0.721	0.625	0.448	0.556	0.462	0.346	0.406	0.572	0.575	0.547
	-18%	-2%	-21%	-26%	-27%	-1%	-7%	-6%	-8%	14%	-1%	-2%	-8%

جدول 11: نتائج التجربة الثالثة.


فيما يوضح الرسم البياني نتائج التجربة ومقارنتها مع mBert.




ويبين الرسم أدناه مقارنة mBert مع أفضلهم.





فيما يبين الرسم أدناه مقارنة نتائج النموذج مع إضافة الاشعة إليه.



وبين الشكل أدناه كيف أن الإضافات التي قمنا بها على التمثيل جعلت التمثيل باستخدام arabert مستقرّاً أكثر.




وبين الشكل أدناه نتائج العقدة على كتلة رسائل، في التجارب السابقة.




التجربة الرابعة: النموذج المرجعي HCRC

في هذه التجربة تم تقييم النموذج المرجعي ومختلف أجزائه بالنمط الحي.


يبين الشكل أدناه الفرق بين أداء النموذج المرجعي HCRC مع أفضل نموذج كنا قد حصلنا عليه وهو mBert، حيث يلاحظ استقرار النموذج خلال الأيام، على عكس mBert الذي كانت نتائجه تتفاوت حسب الأيام




ويوضح الشكل أدناه الفرق بين نتائج مكوناته



ويبين الشكل أدناه الفرق بين أدائه بدون القيام بعملية التدريب الدورية.



فيما يبين الشكل أدناه النتائج للنموذج Graph + Node + mBert + 2PCA، مع تعديل عملية التدريب لتصبح دورية عوضاً عن أن تكون قبل كل يوم، مقابل النموذج HCRC



الفصل التاسع


تنجيز النظام

يعرض هذا الفصل كيفية تنجيز النظام.


1.1- مقدمة

خلال عملية تطوير الخدمات يتم رفع الرماز المصدري الخاص بكل خدمة باستخدام Git إلى مستودع (Repository) ضمن الموقع Github، ضمن فرع Branch يسمى dev يرمز إلى مرحلة التطوير، حيث عند إضافة ميزة جديدة يتم إنشاء فرع انطلاقاً من الفرع dev، وعند الانتهاء منها يتم طلب دمج فرعها مع فرع التطوير بعد تشغيل خط أنابيب الاختبار Pipeline الخاصة باختبارات الوحدة والتكامل والجودة لها، وبذلك نضمن أن فرع التطوير dev يحوي على رماز مصدري مختبر ويعمل، وضمن الجودة المرجوة. وبهذه الطريقة نكون قد حققنا التكامل المستمر (Continues Integration).

يوضح الشكل أدناه الخدمات المنجزة، حيث كل خدمة منفصلة ولها مستودع خاص بها واختباراتها وخط أنابيب لها.



وعند تنجزنا للخدمات المطورة باستخدام لغة Python، أملينا على أنفسنا مجموعة من القواعد، لبناء خدمة قابلة للتوسع وإعادة الاستخدام بسهولة، اعتمدنا في وضعها على البنية المعمارية النظيف، ومعمارية الشرائح العمودية Vertical Slice Architecture. بحيث تساعدنا في وضع المكونات التي تتغير سوية بجانب بعضها، وإبقاء المكونات المستقرة بجانب بعضها.



بحيث، في كل مشروع يكون هنالك مكون يحتوي على

تجريدات Abstraction،


وعندما نريد إضافة ميزة ما، فإن كل ما علينا هو إضافة

مجلد باسمها، إضافة تجريد لها ضمن مجلدها، وكتابة

التنجزات الممكنة وتعريف المسجل، تعريف آلية


بناءها.

وبالنسبة للخدمات المعتمدة على إطار العمل ASP.NET، اعتمدت البيئة المعمارية النظيفه وفق المشاريع موضحة بالشكل أدناه



2.1- تنجيز الخدمات

خدمة سحب البيانات




```
async for task in tasks_service.stream_tasks():
    scraper = factory.create_scraper(task.scraping_approach)

    agent.set_scraper(scraper)
    agent.assign_task(task)
    await agent.run()
```



خدمة إدارة عمليات السحب





خدمة كشف الأحداث

خدمة الاستدلال على الموقع

```
> env
> notebooks
> public
✓ src
  ✓ app
    ✓ core
      > configs
      > factory
      > models
      > services
      + _init_.py
      > routes
      + _init_.py
      + main.py
    > tests
  .env
```

خدمة إدارة الأحداث






خدمة البوابة

خدمة واجهة المستخدم

خدمة الهوية



خدمة استخراج الكيانات المسماة

```
> env
> public
✓ src
  > .pytest_cache
  ✓ app
    ✓ core
      > configs
      > factory
      > models
      > services
      📄 __init__.py
      > routes
      📄 __init__.py
      📄 main.py
    > tests
```

3.1- مخطط النظام

يهدف

3.1- نشر الخدمات

الفصل العاشر

تحليل ومناقشة النتائج

يوضح هذا الفصل بعض المفاهيم المستخدمة في هذا العمل.

1.1- مقدمة

تعتبر الصفحات

2.1- معايير التقييم

ن

الفصل الحادي عشر

اختبارات النظام

يوضح هذا الفصل بعض المفاهيم المستخدمة في هذا العمل.

1.1- مقدمة

تعتبر الـ.

2.1- اختبار خدمات النظام

اختبار خدمة سحب البيانات

يوضح الشكل أدناه نتائج اختبار خدمة سحب البيانات حيث كانت قادرة على معالجة 75 ألف رسالة بمتوسط عشر رسائل كل ثانية.


```

[INFO] Filtered out 0 messages.
[INFO] Published batch to topic Telegram.Politics: 20 messages
[INFO] First message in batch: 'رقم مالع! لئاسو لجاع' with label=positive, score=0.963
[INFO] Embeddings generated successfully.
[INFO] Starting classification with 8 messages
[INFO] Filtered out 0 messages.
[INFO] Published batch to topic Telegram.Politics: 8 messages
[INFO] First message in batch: 'رقم مالع! لئاسو لجاع' with label=positive, score=0.693
..' with label=positive, score=0.693
Processed 28224 messages in 2641.80s -> 10.68 msgs/se
c

[✓] Total messages processed: 75865
.

===== 1 passed in 7087.29s (1:58:07) =====
(env) PS D:\SAS\SAS.ScapingAgent>

```



اختبار خدمة سحب البيانات

3.1- اختبارات الأداء

ي

الخاتمة والآفاق المستقبلية

يهدف هذا الجزء كما تشير تسميته إلى تحديد الغاية من المشروع وتعريف دفتر شروطه الأولي، بالإضافة إلى لمحة عما تم إنجازه فعلياً خلال العمل. يفضل أن يخلو الملخص من المقدمات بحيث لا يتجاوز نصف صفحة. ننصح أيضاً بكتابة نفس الملخص باللغة الإنكليزية (على نفس الصفحة إن أمكن) وذلك بغية التعريف بالعم بشكل أوسع عبر محركات بحث الإنترنت إذا تم وضع التقرير إلكترونياً على الشبكة. (Zhang et al., 2021)

عادةً ما تُطبع صفحة الخلاصة أيضاً على الواجهة الخلفية للتقرير المسماة بالغلاف الرابع (Forth cover)، مما يمكن الآخرين

المراجع

- [1.] Abagissa, A. T., Saxena, S., & Chandra, J. (2024). *Distilbert-gnn: A Powerful Approach to Social Media Event Detection*. In Review. <https://doi.org/10.21203/rs.3.rs-4193412/v1>
- [2.] Afyouni, I., Aghbari, Z. A., & Razack, R. A. (2022). Multi-feature, multi-modal, and multi-source social event detection: A comprehensive survey. *Information Fusion*, 79, 279–308. <https://doi.org/10.1016/j.inffus.2021.10.013>
- [3.] Afyouni, I., Khan, A., & Aghbari, Z. A. (2022). Deep-Eware: Spatio-temporal social event detection using a hybrid learning model. *Journal of Big Data*, 9(1), 86. <https://doi.org/10.1186/s40537-022-00636-w>
- [4.] Aggarwal, C. C., Yu, P. S., Han, J., & Wang, J. (2003). A Framework for Clustering Evolving Data Streams. In *Proceedings 2003 VLDB Conference* (pp. 81–92). Elsevier. <https://doi.org/10.1016/B978-012722442-8/50016-1>
- [5.] Alharbi, A., & Lee, M. (n.d.). *Kawarith: An Arabic Twitter Corpus for Crisis Events*.
- [6.] Alsaedi, N., & Burnap, P. (2015). Arabic Event Detection in Social Media. In A. Gelbukh (Ed.), *Computational Linguistics and Intelligent Text Processing* (Vol. 9041, pp. 384–401). Springer International Publishing. https://doi.org/10.1007/978-3-319-18111-0_29
- [7.] Alsaedi, N., Burnap, P., & Rana, O. (2021). Sensing Real-World Events Using Arabic Twitter Posts. *Proceedings of the International AAAI Conference on Web and Social Media*, 10(1), 515–518. <https://doi.org/10.1609/icwsm.v10i1.14765>
- [8.] Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2017). *Enriching Word Vectors with Subword Information* (No. arXiv:1607.04606). arXiv. <https://doi.org/10.48550/arXiv.1607.04606>
- [9.] Bok, K., Kim, I., Lim, J., & Yoo, J. (2023). Efficient graph-based event detection scheme on social media. *Information Sciences*.
- [10.] Cao, P., Chen, Y., Zhao, J., & Wang, T. (2020). Incremental Event Detection via Knowledge Consolidation Networks. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 707–717. <https://doi.org/10.18653/v1/2020.emnlp-main.52>
- [11.] Cao, Y., Peng, H., Wu, J., Dou, Y., Li, J., & Yu, P. S. (2021). Knowledge-Preserving Incremental Social Event Detection via Heterogeneous GNNs. *Proceedings of the Web Conference 2021*, 3383–3395. <https://doi.org/10.1145/3442381.3449834>
- [12.] Cao, Y., Peng, H., Yu, Z., & Yu, P. S. (2023). *Hierarchical and Incremental Structural Entropy Minimization for Unsupervised Social Event Detection* (No. arXiv:2312.11891). arXiv. <https://doi.org/10.48550/arXiv.2312.11891>
- [13.] Corney, D., Martin, C., & Göker, A. (2014). Spot the Ball: Detecting Sports Events on Twitter. In M. De Rijke, T. Kenter, A. P. De Vries, C. Zhai, F. De Jong, K. Radinsky, & K. Hofmann (Eds.), *Advances in Information Retrieval* (Vol. 8416, pp. 449–454). Springer International Publishing. https://doi.org/10.1007/978-3-319-06028-6_40
- [14.] Deng, S., Zhang, N., Kang, J., Zhang, Y., Zhang, W., & Chen, H. (2020). Meta-Learning with Dynamic-Memory-Based Prototypical Network for Few-Shot Event Detection. *Proceedings of the 13th International Conference on Web Search and Data Mining*, 151–159. <https://doi.org/10.1145/3336191.3371796>

- [15.] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* (No. arXiv:1810.04805). arXiv. <https://doi.org/10.48550/arXiv.1810.04805>
- [16.] Fedoryszak, M., Frederick, B., Rajaram, V., & Zhong, C. (2019). Real-time Event Detection on Social Data Streams. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2774–2782. <https://doi.org/10.1145/3292500.3330689>
- [17.] George, Y., Karunasekera, S., Harwood, A., & Lim, K. H. (2021). *Real-time spatio-temporal event detection on geotagged social media*.
- [18.] Ghaemi, Z., & Farnaghi, M. (2023). Event detection from geotagged tweets considering spatial autocorrelation and heterogeneity. *Journal of Spatial Science*, 68(3), 353–371. <https://doi.org/10.1080/14498596.2021.2002201>
- [19.] Guille, A., & Favre, C. (2015). Event detection, tracking, and visualization in Twitter: A mention-anomaly-based approach. *Social Network Analysis and Mining*, 5(1), 18. <https://doi.org/10.1007/s13278-015-0258-0>
- [20.] Guo, Y., Zang, Z., Gao, H., Xu, X., Wang, R., Liu, L., & Li, J. (2024). Unsupervised Social Event Detection via Hybrid Graph Contrastive Learning and Reinforced Incremental Clustering. *Knowledge-Based Systems*, 284, 111225. <https://doi.org/10.1016/j.knosys.2023.111225>
- [21.] Hamoui, B., Mars, M., & Almotairi, K. (n.d.). *FloDusTA: Saudi Tweets Dataset for Flood, Dust Storm, and Traffic Accident Events*.
- [22.] Hasan, M., Orgun, M. A., & Schwitter, R. (2016). *TwitterNews: Real time event detection from the Twitter data stream*. PeerJ Preprints. <https://doi.org/10.7287/peerj.preprints.2297v1>
- [23.] Hettiarachchi, H., Adedoyin-Olowe, M., Bhogal, J., & Gaber, M. M. (2022). Embed2Detect: Temporally Clustered Embedded Words for Event Detection in Social Media. *Machine Learning*, 111(1), 49–87. <https://doi.org/10.1007/s10994-021-05988-7>
- [24.] Hossny, A. H., & Mitchell, L. (2019). *Event detection in Twitter: A keyword volume approach* (No. arXiv:1901.00570). arXiv. <https://doi.org/10.48550/arXiv.1901.00570>
- [25.] Igartua, M. A., Almenares, F., Redondo, R. P. D., Martín, M. I., Forné, J., Campo, C., Fernández, A., Cruz, L. J. de la, García-Rubio, C., Marínn, A., Mezher, A. M., Díaz, D., Cerezo, H., Rebollo-Monedero, D., Arias, P., & Rico, F. (2020). INRISCO: INcident monitoRing In Smart COMMunities. *IEEE Access*, 8, 72435–72460. <https://doi.org/10.1109/ACCESS.2020.2987483>
- [26.] Kovalchuk, M. A., Filatova, A., Korneev, A., Koreneva, M., Nasonov, D., Voskresenskii, A., & Boukhanovsky, A. (2024). SemConvTree: Semantic Convolutional Quadrees for Multi-Scale Event Detection in Smart City. *Smart Cities*, 7(5), 2763–2780. <https://doi.org/10.3390/smartcities7050107>
- [27.] Li, P., Yu, X., Peng, H., Xian, Y., Wang, L., Sun, L., Zhang, J., & Yu, P. S. (2024). *Relational Prompt-based Pre-trained Language Models for Social Event Detection* (No. arXiv:2404.08263). arXiv. <https://doi.org/10.48550/arXiv.2404.08263>
- [28.] Li, Q., Chao, Y., Li, D., Lu, Y., & Zhang, C. (2022). Event Detection from Social Media Stream: Methods, Datasets and Opportunities. *2022 IEEE International Conference on Big Data (Big Data)*, 3509–3516. <https://doi.org/10.1109/BigData55660.2022.10020411>

- [29.] Li, Q., & Zhang, Q. (2021). Twitter Event Summarization by Exploiting Semantic Terms and Graph Network. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(17), 15347–15354. <https://doi.org/10.1609/aaai.v35i17.17802>
- [30.] McMinn, A. J., Moshfeghi, Y., & Jose, J. M. (2013). Building a large-scale corpus for evaluating event detection on twitter. *Proceedings of the 22nd ACM International Conference on Information & Knowledge Management*, 409–418. <https://doi.org/10.1145/2505515.2505695>
- [31.] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space* (No. arXiv:1301.3781). arXiv. <https://doi.org/10.48550/arXiv.1301.3781>
- [32.] Morabia, K., Murthy, N. L. B., Malapati, A., & Samant, S. (n.d.). *SEDTWik: Segmentation-based Event Detection from Tweets Using Wikipedia*.
- [33.] Olteanu, A., Castillo, C., Diaz, F., & Vieweg, S. (2014). CrisisLex: A Lexicon for Collecting and Filtering Microblogged Communications in Crises. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 376–385. <https://doi.org/10.1609/icwsm.v8i1.14538>
- [34.] Patil, P., Patil, P., Salvi, A., & Hatiskar, M. (2015). *Social Sensor for Real Time Event Detection*. 5(3).
- [35.] Peng, H., Zhang, R., Li, S., Cao, Y., Pan, S., & Yu, P. S. (2023). Reinforced, Incremental and Cross-Lingual Event Detection From Social Messages. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1), 980–998. <https://doi.org/10.1109/TPAMI.2022.3144993>
- [36.] Pradhan, A. K., Mohanty, H., & Lal, R. P. (2024). EDTBERT: Event Detection and Tracking in Twitter using Graph Clustering and Pre-trained Language Model. *Procedia Computer Science*, 233, 481–491. <https://doi.org/10.1016/j.procs.2024.03.238>
- [37.] Qazi, U., Imran, M., & Ofli, F. (2020). GeoCoV19: A Dataset of Hundreds of Millions of Multilingual COVID-19 Tweets with Location Information. *SIGSPATIAL Special*, 12(1), 6–15. <https://doi.org/10.1145/3404820.3404823>
- [38.] Ray, M., Wang, Q., Mélanie-Becquet, F., Poibeau, T., & Mazoyer, B. (2024). An Incremental Clustering Baseline for Event Detection on Twitter. *Proceedings of the Workshop on the Future of Event Detection (FuturED)*, 18–24. <https://doi.org/10.18653/v1/2024.futured-1.2>
- [39.] Ren, J., Jiang, L., Peng, H., Cao, Y., Wu, J., Yu, P. S., & He, L. (2022). *From Known to Unknown: Quality-aware Self-improving Graph Neural Network for Open Set Social Event Detection* (No. arXiv:2208.06973). arXiv. <https://doi.org/10.48550/arXiv.2208.06973>
- [40.] Saeed, Z., Abbasi, R. A., Maqbool, O., Sadaf, A., Razzak, I., Daud, A., Aljohani, N. R., & Xu, G. (2019). What’s Happening Around the World? A Survey and Framework on Event Detection Techniques on Twitter. *Journal of Grid Computing*, 17(2), 279–312. <https://doi.org/10.1007/s10723-019-09482-2>
- [41.] Saeed, Z., Abbasi, R. A., Razzak, M. I., & Xu, G. (2019). *Event Detection in Twitter Stream using Weighted Dynamic Heartbeat Graph Approach* (No. arXiv:1902.08522). arXiv. <https://doi.org/10.48550/arXiv.1902.08522>
- [42.] Schinas, M., Papadopoulos, S., Kompatsiaris, Y., & Mitkas, P. (2018). *Event Detection and Retrieval on Social Media* (Version 1). arXiv. <https://doi.org/10.48550/ARXIV.1807.03675>

- [43.] Suwaileh, R., Elsayed, T., & Imran, M. (2023). IDRISI-D: Arabic and English Datasets and Benchmarks for Location Mention Disambiguation over Disaster Microblogs. *Proceedings of ArabicNLP 2023*, 158–169. <https://doi.org/10.18653/v1/2023.arabnlp-1.14>
- [44.] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). *Attention Is All You Need* (No. arXiv:1706.03762). arXiv. <https://doi.org/10.48550/arXiv.1706.03762>
- [45.] Wang, X., Wang, Z., Han, X., Jiang, W., Han, R., Liu, Z., Li, J., Li, P., Lin, Y., & Zhou, J. (2020). *MAVEN: A Massive General Domain Event Detection Dataset* (No. arXiv:2004.13590). arXiv. <https://doi.org/10.48550/arXiv.2004.13590>
- [46.] Yamani, A., Alsulami, A., & Al-Zaidy, R. (n.d.). *Event-Based Knowledge MLM for Arabic Event Detection*.
- [47.] Yang, Z., Wei, Y., Li, H., Li, Q., Jiang, L., Sun, L., Yu, X., Hu, C., & Peng, H. (2024). Adaptive Differentially Private Structural Entropy Minimization for Unsupervised Social Event Detection. *Proceedings of the 33rd ACM International Conference on Information and Knowledge Management*, 2950–2960. <https://doi.org/10.1145/3627673.3679537>
- [48.] Yu, X., Wei, Y., Zhou, S., Yang, Z., Sun, L., Peng, H., Zhu, L., & Yu, P. S. (2024). *Towards Effective, Efficient and Unsupervised Social Event Detection in the Hyperbolic Space* (No. arXiv:2412.10712). arXiv. <https://doi.org/10.48550/arXiv.2412.10712>
- [49.] Yue, Z., Zeng, H., Lan, M., Ji, H., & Wang, D. (2023). Zero- and Few-Shot Event Detection via Prompt-Based Meta Learning. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 7928–7943. <https://doi.org/10.18653/v1/2023.acl-long.440>
- [50.] Zhang, C., Zhou, G., Yuan, Q., Zhuang, H., Zheng, Y., Kaplan, L., Wang, S., & Han, J. (2016). GeoBurst: Real-Time Local Event Detection in Geo-Tagged Tweet Streams. *Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 513–522. <https://doi.org/10.1145/2911451.2911519>
- [51.] Zhang, S., Cheng, Y., & Ke, D. (2017). *Event-Radar: Real-time Local Event Detection System for Geo-Tagged Tweet Streams* (No. arXiv:1708.05878). arXiv. <https://doi.org/10.48550/arXiv.1708.05878>

الملاحق

ملحق أ

الدراسة الكميّة

نبين هنا الأرقام والقياسات التي يجب أن يعمل ضمنها النظام

مقدمة

تهدف من هذه الدراسة إلى تقدير الكميات المطلوبة لتصميم وتشغيل نظام كشف ومراقبة الأحداث في وسائل التواصل الاجتماعي.

عدد الأحداث اليومي

في بلد جميل مثل سوريا، وي مرحلة مفصلية في تاريخها كما اليوم، بدأت البلاد تخطو خطوات حثيثة نحو إعادة البناء، سواء على مستوى البنية التحتية أو على مستوى الإنسان والمجتمع. وفي هذا السياق، أصبحت الأحداث اليومية أكثر كثافة وتنوعاً، ليس فقط بسبب التحديات، بل لأن الحركة في المجتمع تعود تدريجياً، ويتفاعل الناس مع الواقع من جديد عبر وسائل الإعلام التقليدي والاجتماعي. ففي مدينة مثل دمشق، أو حلب، يمكن أن نسجل يومياً عشرات الأحداث التي تشمل:

- إطلاق مشاريع خدمية جديدة - فعاليات تعليمية وصحية
- حالات استجابة للطوارئ - حوادث بسيطة أو أعطال بنية تحتية

وبناءً على البيانات التي جمعناها، يمكن تقدير عدد الأحداث اليومية في المدن الكبرى بـ 10 إلى 100 حدث يوميًا، أي في عموم البلاد يمكن أن يصل وسطياً إلى 500 حدث. وفي حالات الكوارث الطبيعية والأزمات، قد يرتفع هذا العدد إلى أكثر من ذلك بعشرات الأضعاف، ففي الأوقات ذات الطابع الطارئ أو عند وقوع كوارث طبيعية كبرى، فمثلاً، في زلزال 6 شباط 2023، حيث توالى البلاغات والمعلومات من جميع أنحاء البلاد خلال ساعات قليلة، يمكن أن يرتفع العدد إلى 5000 حدث في يوم واحد.

كمية البيانات الواجب سحبها

بناءً على تحليل الكلمات مفتاحية مرتبطة بالأحداث العامة، تُقدّر أن عدد التغريدات اليومية المرتبطة بالشأن السوري التي يتم تداولها، يتراوح بين 3,000 إلى 20,000 تغريدة في الأيام العادية، خاصة تلك المتعلقة بالخدمات، الأمن، الصحة، والنشاطات المجتمعية.

في الأوقات الخاصة مثل الكوارث أو الأزمات، يتضاعف هذا الرقم. فعلى سبيل المثال، خلال زلزال 6 شباط 2023، تم تسجيل أكثر من 500,000 تغريدة خلال أول 24 ساعة تتعلق مباشرة بالحدث ومجرياته، وفق تقارير تحليلية. وكذلك، في أحداث ذات طابع سياسي أو عسكري، مثل التصعيدات الإسرائيلية- الإيرانية، قد يصل حجم التفاعل إلى 100,000 تغريدة أو أكثر في اليوم الواحد.

معدل دفع التغريدات

في الأيام الاعتيادية، ومع مراقبة كلمات مفتاحية محددة مرتبطة بالخدمات أو الأمن أو النشاطات المجتمعية، قد يصل معدل التدفق إلى 100 – 300 تغريدة في الدقيقة الواحدة، أي ما يعادل تقريباً 2 إلى 5 تغريدات في الثانية.

عند حدوث أمر طارئ أو لافِت، مثل انقطاع كبير للكهرباء، حادث مروري واسع النطاق، أو حتى حدث ثقافي ضخم، يقفز هذا الرقم إلى ما يزيد عن 1000 تغريدة في الدقيقة – أي ما يقارب 16 تغريدة في الثانية، وأحياناً أكثر.

في حالات الكوارث الكبرى – مثل الزلازل أو التصعيدات العسكرية المفاجئة – يمكن أن يتضاعف هذا الرقم بسهولة، ليصل إلى 5000 تغريدة في الدقيقة أو ما يقارب 80 تغريدة في الثانية، موزعة بين تحديثات إخبارية، صور من شهود عيان، بلاغات غير رسمية، ومناشدات استغاثة.

عدد المستخدمين المتوقع

في مرحلة إعادة البناء، لا تُبنى البلاد بالأسمنت فقط، بل بالوعي، بالمعلومة، وبالقدرة على الوصول السريع إلى ما يحدث. ولهذا، فإن نظام كشف الأحداث ليس موجّهاً فقط لصنّاع القرار أو الجهات الأمنية، بل أيضاً للمواطن، وللصحفي، وللخدمة العامة التي تسعى لأن تكون حاضرة في المكان الصحيح في الوقت المناسب.

المستخدمون الداخليون (المسجلون، المراقبون):

هؤلاء المستخدمون يأتون من مستخدمي الراغبين بتلقي التنبيهات، المراسلين، الإعلاميين، ومحليي البيانات، المهتمين بالشأن السوري.

التقدير المبدئي يشير إلى ما بين 300 إلى 1000 مستخدم داخلي نشط يوميّاً، بحسب حجم المنطقة الجغرافية التي يخدمها النظام وعدد الجهات المتعاونة معه.

المستخدمون الخارجيون (الجمهور غير المسجلين):

يمكن أن يصل إلى 1000 – 50,000 تصفح نشط يوميّاً في المرحلة الأولى، وقد يتجاوز 100,000 مستخدم يوميّاً في حالات الأزمات الكبيرة أو عند تغطية أحداث تهم الرأي العام.

ملحق ب

دليل تنميط مجموعة البيانات

نرفق هنا الدليل الذي تم وضعه لتنميط مجموعة البيانات.

دليل تعليمات تصنيف التغريدات

يهدف هذا الملف إلى توضيح كيفية تصنيف التغريدات المرفقة إلى فئتين: ذات صلة بالمسألة (Relevant) وغير ذات صلة (Not Relevant).

الغرض

قم بوضع علامة على كل تغريدة على أنها ذات صلة أو غير ذات صلة استناداً إلى ما إذا كانت تحتوي على معلومات مفيدة حول الأحداث المتعلقة بالسياق المستهدف (على سبيل المثال، الحوادث، والكوارث، والاحتجاجات، والصراعات) التي تريد اكتشافها

معايير التصنيف

ذات صلة: تتضمن معلومات عن حدث وقع بالفعل أو يجري حالياً أو سيحدث مستقبلاً، مثل تقارير عن هجمات، مظاهرات، اجتماعات سياسية، كوارث طبيعية، إلخ.

غير ذات صلة: لا تتضمن أي معلومات تتعلق بحدث فعلي، مثل الآراء العامة، النكات، النقاشات الدينية أو الطائفية دون ذكر حدث محدد.

أمثلة على تصنيف التغريدات

السبب	التصنيف	التغريدة
تقرير عن موقف سياسي	Relevant	أ ف ب عن قيادي كردي بارز: لا تنازل عن مطلب اللامركزية في محادثاتنا مع #دمشق
رأي بدون معلومات عن حدث	Not Relevant	مذيعين من الشارع، حقد طائفي وقومي -مش هيك الإعلام، مش هيك التعايش بيصير.
محتوى اجتماعي بدون علاقة بحدث	Not Relevant	وحده يمنية نزلت منشور في التيك توك إنها تخطبت لسوري. الردود من السوريين شيء يخجل

تقرير عن حدث سياسي/عسكري	Relevant	تركيا تسعى لإنشاء قاعدتين «بحرية وجوية» في سوريا
مزحة أو رأي بدون ذكر حدث	Not Relevant	@mehmod_kolo و هو راح سأل جميع السوريين ههههه 😊
تقرير عن حادثة ورد فعل	Relevant	الموساد ينقذ عملية إنزال جوي في حمص، سوريا